פתרון לממ"ן 21 – פרויקט גמר בקורס כריית מידע 20595

שם: לינוי ביטון

ת.ז: 211589775

שאלה 1: הגדרת הבעיה והכנת הנתונים

א. מטרת כריית המידע, הנחות והפשטות:

מטרת כריית המידע:

המטרה המרכזית בפרויקט זה היא **לזהות מטופלים המצויים בסיכון לשבץ מוחי** (stroke) בהתבסס על מאפיינים קליניים, דמוגרפיים והרגלי חיים, כפי שמופיעים במאגר הנתונים באתר Kaggle בכתובת https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset :

בעזרת אלגוריתמים לכריית מידע, נבנה מודלים הממפים בין תכונות כמו גיל, לחץ דם, רמת סוכר ומחלות רקע לבין הסיווג הבינארי – "לקה בשבץ" / "לא לקה".

מטרות ממוקדות:

- לזהות משתנים המשפיעים על סיכון לשבץ.
- לאמן שני מודלי סיווג ולהשוות ביניהם.
- להעריך את הביצועים על בסיס מדדי דיוק רלוונטיים.
- להסיק מסקנות מעשיות לשימוש עתידי.

הנחות עבודה:

- הנתונים סופקו באמינות מתוך מקורות רפואיים או סינתטיים מבוקרים.
- כל רשומה מייצגת נבדק ייחודי (כלומר, אין תלות בין שורות).
- אין תלות זמנית בין התצפיות (ניתוח מסוג "Snapshot").
- הנתונים כוללים גם ערכים חסרים ובעיות איזון – שיטופלו בשלב העיבוד.
- כל המידע הקיים נלקח כפי שהוא – לא נאסף מידע חיצוני נוסף.

הפשטות:

- ההתמקדות היא בחיזוי בינארי בלבד ("שבץ" / "לא").
- לא נתחשב במידת חומרת השבץ או במיקום הגיאוגרפי של המטופלים.
- אנליזת זמן עד לאירוע (time to stroke) אינה נכללת.
- לא יבוצע ניתוח קליני רפואי – נסתמך רק על הנתונים שבקובץ.

ב. הגדרת הנתונים:

המאגר מכיל נתונים קליניים ודמוגרפיים של נבדקים מכלל האוכלוסייה, שנאספו ממקורות רפואיים ופורסמו בפלטפורמת Kaggle , כל שורה מייצגת אדם אחד, כאשר עמודת המטרה היא – "stroke" ערך בינארי המציין האם האדם לקה בשבץ מוחי (1) או לא (0). הנתונים כוללים תכונות כמו גיל, מגדר, מחלות רקע, הרגלי חיים ועוד.

הטבלה הבאה מסכמת את התכונות המרכזיות בסט הנתונים:

שם התכונה	תיאור התכונה	סוג הנתונים	ערכים אפשריים / טווחים	ממוצע	טווח ערכים מספריים	אחוז ערכים חסרים	נתונים חסרים
gender	מגדר הנבדק	קטגוריאלי	Female / Male / Other	N/A	–	0.0%	לא
age	גיל הנבדק (בערכים עשרוניים)	מספרי רציף	0 – 82 שנים	43.23	0.08 – 82.0	0.0%	לא
hypertension	האם סובל מלחץ דם גבוה	בינארי	0 (לא) / 1 (כן)	0.10	0 – 1	0.0%	לא
heart_disease	האם סובל ממחלת לב	בינארי	0 (לא) / 1 (כן)	0.05	0 – 1	0.0%	לא
ever_married	האם היה/הייתה נשוי/אה	קטגוריאלי	Yes / No	N/A	–	0.0%	לא
work_type	תחום העיסוק	קטגוריאלי	Private, Self-employed וכו'	N/A	–	0.0%	לא
Residence_type	מקום מגורים (עיר/כפר)	קטגוריאלי	Urban / Rural	N/A	–	0.0%	לא
avg_glucose_level	רמת סוכר ממוצעת בדם	מספרי רציף	כ־55 – 270 mg/dL	106.15	55.12 – 271.74	0.0%	לא
bmi	מדד מסת גוף	מספרי רציף	כ־10 – 98 (kg/m²)	28.89	10.3 – 97.6	3.9%	כן
smoking_status	מצב עישון	קטגוריאלי	never, formerly, smokes וכו'	N/A	–	30.4%	כן
stroke	עמודת המטרה – האם התרחש שבץ	בינארי	0 (לא) / 1 (כן)	0.05	0 – 1	0.0%	לא

תובנות ראשוניות:

- קיימים ערכים חסרים בעמודות (bmi, smoking_status, gender) במקרים בודדים.
- עמודת age מכילה ערכים עשרוניים – יישקל נירמול או דיסקרטיזציה בהמשך.
- עמודת stroke אינה מאוזנת – יש צורך לבדוק את שיעור המופעים ולהיערך לטיפול במצב של חוסר איזון (class imbalance) .
- ייתכן ששדות מסוימים לא תורמים לחיזוי – תתבצע הערכת רלוונטיות (feature selection) בהמשך.

ג. תיאור שלבי תהליך KDD עבור הבעיה:

תהליך ה־ KDD (Knowledge Discovery in Databases) מורכב ממספר שלבים עוקבים, אשר יושמו בפרויקט זה בצורה המותאמת לבעיה הרפואית של חיזוי שבץ מוחי:

1) הגדרת מטרות כריית המידע

המטרה המרכזית היא לבנות מודל חיזוי אשר יזהה נבדקים המצויים בסיכון מוגבר לשבץ מוחי, בהתבסס על סט תכונות דמוגרפיות, רפואיות והרגלי חיים.

2) איסוף ושילוב הנתונים

הנתונים נאספו ממאגר Kaggle ומקורם הוא בקובץ CSV אחד, ולכן לא נדרש שילוב בין מקורות שונים. כל שורה מייצגת נבדק עצמאי, וכל עמודה תכונה. עמודת המטרה היא — stroke ערך בינארי.

נמצא חוסר איזון חמור בנתונים כ־5% בלבד עם stroke=1 , מה שהכתיב התייחסות מיוחדת בהמשך בתהליך האיזון.

3) ניקוי נתונים

בוצעה סקירה ראשונית לאיתור ערכים חסרים ושגויים:

- נמצא כי יש ערכים חסרים בעמודות bmi, gender, smoking_status.
- בוצע ניקוי או השלמה של ערכים חסרים בהתאם לגישה שתיבחר בשלב ההכנה (למשל: השלמה לפי ממוצע או הסרה).
- תיבדק גם עקביות של ערכים קטגוריאליים (למשל, ערכים לא צפויים בשדה מגדר).

4) טרנספורמציה והכנה לכרייה

- תכונות רציפות כגון age, bmi ו־ avg_glucose_level ייבחנו לצורך נירמול או דיסקרטיזציה.
- יישקל איחוד קטגוריות במשתנים כגון smoking_status אם תתגלה שונות נמוכה בין חלק מהקטגוריות.
- יוצגו גרפים לבחינת התפלגות התכונות והקשרים ביניהן לבין משתנה המטרה.
- בוצעה המרה ל־ One-Hot Encoding רק עבור Residence_type ו־ ever_married ואילו תכונות כמו smoking_status ו־ work_type קודדו לפי Frequency Encoding כדי לשמר מידע על שכיחות ולהפחית ממדיות.
- בוצעה הנדסת תכונות (Feature Engineering) מתקדמת הכוללת משתנים חדשים כמו:
  - יחס בין גלוקוז לגיל (glucose_age_ratio)

- מכפלת BMI וגיל (bmi_age_product)
- אינטראקציה בין גיל למחלות רקע (age_hypertension, heart_senior_interaction)
- משתנה בינארי is_senior לגיל מעל 60

- המשתנים נבחרו במטרה לחשוף קשרים מורכבים שאינם מופיעים בתכונות הגולמיות.
- הנדסת התכונות התבססה בין היתר על גישות מודרניות כמו אלו של XGBoost ו־ CatBoost אשר מזהות תכונות אינטראקטיביות לא ליניאריות, ותרמו לבחירת משתנים כמו age_hypertension ו־ glucose_bmi_ratio.
- כמו כן, נוספו תכונות נוספות כגון age_squared, glucose_heart ו־ smoke_age_interaction לצורך העשרת היכולת הליניארית והלא ליניארית של המודלים.

5) בחירת שיטות וכלים

- תהליך ההכנה והכרייה יתבצע ב־ Python באמצעות ספריות pandas, scikit-learn, matplotlib ועוד.
- ייבחרו שתי שיטות סיווג עיקריות לצורך השוואה (כגון Decision Tree, Logistic Regression, Random Forest).
- תבוצע חלוקה ל־ Train/Test או K-Fold לפי הנחיות הסיווג.
- בנוסף לשתי שיטות הסיווג העיקריות, נעשה שימוש באלגוריתמים מתקדמים (XGBoost, CatBoost) לשם סינון תכונות אפקטיבי (Feature Selection) וחישוב סף מותאם לתחזיות Optimized Thresholding, תוך שמירה על התאמה להנחיות הקורס.

6) הרצת שיטות כרייה

- המודלים יאומנו על סט האימון וייבחנו על סט הבדיקה.
- יוצגו תוצאות סיווג, דיוק, מטריצות בלבול ומדדים נוספים (Precision, Recall, F1) .

7) ניתוח והסקת מסקנות

- תיבחן השוואה כמותית ואיכותית בין השיטות.
- תוסקנה מסקנות באשר למשתנים בעלי השפעה גבוהה.
- יוצגו הצעות לשיפור: שיטות נוספות, הנדסת תכונות, טיפול טוב יותר באי־איזון.

<u>ד.</u> סקירה השוואתית בין שיטות סיווג אפשריות

בשלב זה, נבחן מספר שיטות אפשריות לכריית מידע אשר עשויות להתאים לבעיית חיזוי שבץ מוחי על בסיס תכונות המטופלים. ההשוואה מתבצעת על בסיס קריטריונים כגון דיוק, פשטות, רגישות לערכים חסרים, זמן ריצה והתמודדות עם חוסר איזון במחלקות.

1) עץ החלטה מסוג ID3 או C4.5 - Decision Tree

- **יתרונות**:
  - מבנה היררכי ברור, קל לפרשנות והסבר.
  - מתאים לערכים קטגוריאליים ורציפים (לאחר דיסקרטיזציה).

- מאפשר זיהוי משתנים חשובים.

- **חסרונות**:
  - רגיש מאוד לשינויים בנתונים - עלול להיגרר ל־Overfitting.
  - ID3 מוטה לתכונות עם הרבה ערכים - עדיף להשתמש ב־ C4.5 עם Gain Ratio .

- **התאמה לבעיה**:
  - מתאים מאוד לבעיות רפואיות בהן נדרשת שקיפות (Explainability) .

2) Random Forest

- **יתרונות**:
  - עמידות גבוהה לרעש ול־Overfitting.
  - מטפל היטב במשתנים רבים, כולל אינטראקציות מורכבות.
  - נותן אינדיקציה לחשיבות של כל משתנה.

- **חסרונות**:
  - קשה לפרש את המודל – "קופסה שחורה."
  - זמן ריצה גבוה יחסית בעצים רבים.

- **התאמה לבעיה**:
  - אידיאלי לדיוק מירבי, פחות טוב אם נדרשת שקיפות מלאה.

3) Logistic Regression

- **יתרונות**:
  - פשטות, ביצועים טובים במקרים ליניאריים.
  - מספק הסתברויות (ולא רק סיווג).
  - ניתן לפרש את המשקלים של כל משתנה.

- **חסרונות**:
  - רגיש להנחות (כגון קשר ליניארי בין תכונות לתוצאה).
  - פחות מתאים לבעיות עם קשרים לא ליניאריים או אינטראקציות.

- **התאמה לבעיה**:
  - מתאים כקו בסיס ראשוני, או כשהמודל נדרש להיות מוסבר.

4) Naive Bayes

- **יתרונות**:
  - מהיר, פשוט וקל ליישום.
  - עובד טוב עם ערכים חסרים ושיעורי בסיס נמוכים.

- **חסרונות**:

- מניח עצמאות מלאה בין התכונות – הנחה שלא תמיד נכונה רפואית.
- עלול להחמיץ אינטראקציות בין גורמי סיכון.

- **התאמה לבעיה**:
  - יכול לשמש כמודל קל להשוואה, אך ייתכן וביצועיו לא יהיו מיטביים.

סיכום ההשוואה:

שיטה	שקיפות	דיוק צפוי	עמידות ל־Overfitting	זמן ריצה	רגישות לערכים חסרים
Decision Tree (C4.5)	גבוהה	בינוני-גבוה	בינונית	נמוך	בינונית
Random Forest	נמוכה	גבוה	גבוה	גבוה	בינונית
Logistic Regression	גבוהה	בינוני	בינונית	נמוך	בינונית
Naive Bayes	בינונית	בינוני-נמוך	נמוכה	נמוך מאוד	גבוהה

בהמשך העבודה, אבחר שתי שיטות ליישום (למשל: עץ החלטה C4.5 ו־ Random Forest) לצורך השוואת ביצועים וניתוח עומק.

ה. שלבי הכנת הנתונים בפועל

לאחר טעינת הנתונים ממאגר Kaggle , בוצעה סקירה ראשונית להבנת מבנה הקובץ, סוגי התכונות והערכים החסרים.

טיפול בערכים חסרים:

במאגר נמצאו ערכים חסרים בשלוש תכונות bmi, smoking_status, gender :

- בעמודת bmi השלמתי את הערכים החסרים על סמך הממוצע (mean imputation) מתוך הנחה שזהו משתנה רציף בעל התפלגות נורמלית יחסית.
- בעמודת smoking_status השתמשתי בערך השכיח (mode) להשלמה, מכיוון שהיא תכונה קטגוריאלית. בנוסף, ערכים מסוג "Unknown" בעמודת smoking_status נשמרו כקטגוריה נפרדת מתוך כוונה לא לכלול מידע חלקי כערכים חסרים, אלא כהתנהגות נפרדת היכולה לשאת משמעות קלינית בפני עצמה.
- עבור gender, הסרתי את הרשומות בהן הופיע הערך"Other" , שכן מדובר בפחות מ־1% מהדאטה.
- בנוסף, עמודת id שהכילה מזהה ייחודי לכל נבדק הוסרה מהדאטה, מאחר ואינה כוללת מידע בעל ערך חיזויי. מדובר בפרט מזהה בלבד, שאינו רלוונטי למודלי סיווג, ולכן הוסר בשלבי ההכנה.

בדיקת חוסר איזון במחלקות:

נמצא כי רק כ־5% מהרשומות סומנו כמי שלקו בשבץ (stroke = 1) .
לפיכך, ייתכן ויהיה צורך בשלב הבא לבצע איזון מחדש של המחלקות באמצעות oversampling או SMOTE בהתאם לביצועים שיתקבלו בשלב המידול.

כמו כן, SMOTE כן שימש ,אך רק על סט האימון ולא על סט הבדיקה, כדי למנוע – Data Leakage כפי שנעשה בפועל.

כחלק מהכנת הנתונים בוצע גם שילוב טכניקת SMOTETomek לאיזון המחלקות – שילוב של Oversampling מסוג SMOTE עם סינון Tomek Links , שמאפשר גם הגדלת מופעים ממחלקת המיעוט וגם סינון גבולות חפיפה בין מחלקות. בנוסף, בוצע טיוב מתקדם של הנתונים באמצעות הנדסת תכונות הכוללת משתנים חדשים כמו glucose_bmi_ratio, glucose_age_ratio, heart_senior_interaction, bmi_hypertension

ו־ smoke_age_interaction תוך נירמול ערכים וקטיעת קצוות (Outlier Clipping) ל־ glucose ו־ BMI באחוזונים הקיצוניים.

ניתוח תכונות רציפות:

- בוצעה בדיקה האם קיימים ערכים חריגים בגיל (age) רמת סוכר (avg_glucose_level) ומדד מסת גוף (bmi).
- גילאי הנבדקים נעים בין תינוקות לאנשים מבוגרים – אך אין קפיצות או ערכים חריגים מובהקים.
- בתצוגת boxplot של רמת הסוכר לפי עמודת stroke, נראה קשר אפשרי בין רמות סוכר גבוהות לבין שבץ.
- תכונת הגיל נשמרה כמשתנה רציף, מכיוון שהמודלים שנבחרו יודעים להתמודד עם משתנים כאלה.

המרת משתנים קטגוריאליים:

- בוצע קידוד של משתנים קטגוריאליים כך:
- smoking_status ו־work_type קודדו לפי שכיחות (Frequency Encoding), כדי לשמר מידע כמותי ולהימנע מהרחבת ממדיות.
- Residence_type ו־ever_married קודדו באמצעות One-Hot Encoding.

נירמול:

- בוצע נירמול של כל התכונות באמצעות MinMaxScaler לטווח [0–1], לצורך יישור קנה מידה ואחידות בתהליך הסיווג.
- המודלים מבוססי עצים, כמו Random Forest לא הושפעו מהנירמול.

הנדסת תכונות (Feature Engineering) :
בנוסף להכנת הנתונים הבסיסית, בוצעה הנדסת תכונות מתקדמת שמטרתה לחשוף קשרים חבויים בין תכונות ולהעשיר את הדאטה בייצוגים נוספים. נוצרו תכונות חדשות הכוללות יחסים, מכפלות ואינטראקציות בין משתנים:

- glucose_bmi_ratio: יחס בין רמת הגלוקוז ל־ BMI
- glucose_age_ratio: יחס בין רמת הגלוקוז לגיל
- bmi_age_product: מכפלת BMI וגיל
- age_hypertension: מכפלת גיל עם יתר לחץ דם (0 או 1)
- is_senior: משתנה בינארי המציין האם גיל הנבדק מעל 60

- heart_senior_interaction: אינטראקציה בין מחלת לב לגיל מבוגר

תכונות אלה נוספו על סמך הבנה קלינית וניתוחים ראשוניים שבוצעו בדאטה, והן סייעו למודלים להבין טוב יותר דפוסים מורכבים שיכולים להעיד על סיכון לשבץ.

הצגת גרפים תומכים:

- נוצרו גרפים מסוג היסטוגרמות boxplots ו־ countplots כדי לנתח התפלגויות ולזהות מגמות. לדוגמה: נמצא פיזור לא אחיד של גילאים, וריכוז גבוה של מטופלים שאינם מעשנים.

חלוקה לסט אימון וסט בדיקה:

בוצעה חלוקה של הנתונים ל־80% עבור אימון המודלים ו־20% עבור בדיקה, תוך שמירה על שיעור המקרים של stroke בשני הסטים (Stratified Split) .

בנוסף, השתמשתי גם באלגוריתמים מתקדמים כמו CatBoost ו־ XGBoost כדי לבצע בחירה מתקדמת של תכונות וחישוב סף מותאם, אך המודלים העיקריים שנבדקו והושוו הם Decision Tree ו־Random Forest.

סיכום:

בשלב ההכנה טופלו בעיות של ערכים חסרים, אי־התאמות בקטגוריות, וחוסר אחידות בקנה מידה. הגרפים שנוצרו סייעו בגיבוש הבנה טובה יותר של המבנה הפנימי של הדאטה. ההכנה בוצעה מתוך מטרה להנגיש את הנתונים למודלים סיווגיים בצורה שתשפר את ביצועיהם ותקטין את הסיכון ל־overfitting.

גרפים – הצגת הנתונים:

1) **התפלגות גיל המטופלים**
מראה את פיזור הגילאים — מבנה רחב, עם ריכוזים סביב גילאי 50–60.

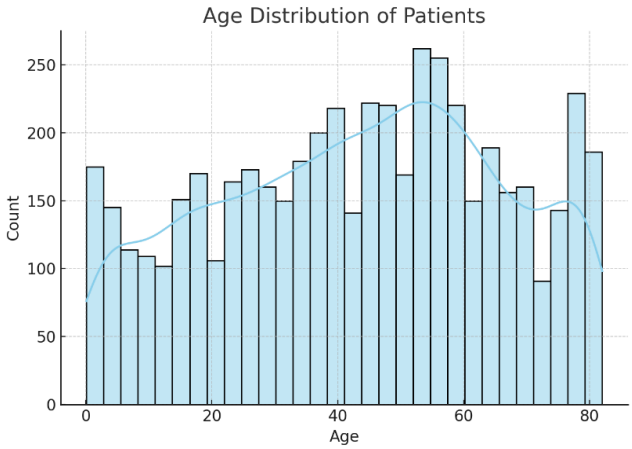

2) **רמת סוכר ממוצעת לפי האם התרחש שבץ (Boxplot)**

מציג בבירור שלחולים שלקו בשבץ יש לרוב ערכים גבוהים יותר של רמות סוכר.

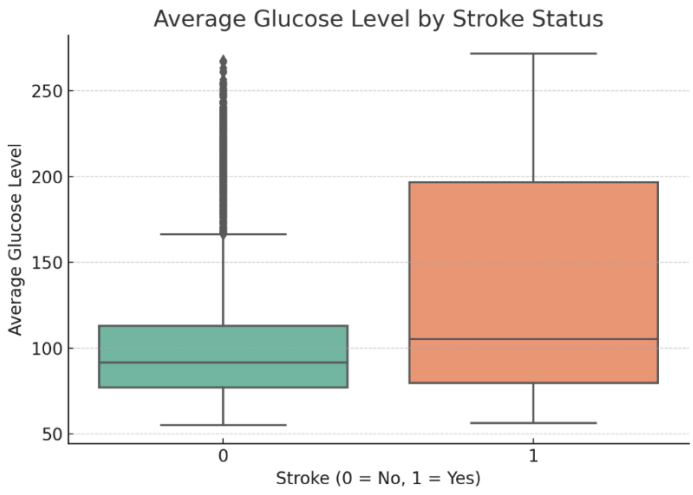

3) **פיזור מצב עישון באוכלוסייה**

מראה כי הרוב המוחלט של הנבדקים מעולם לא עישן, אך קיימת קבוצה לא מבוטלת עם ערך "unknown" .

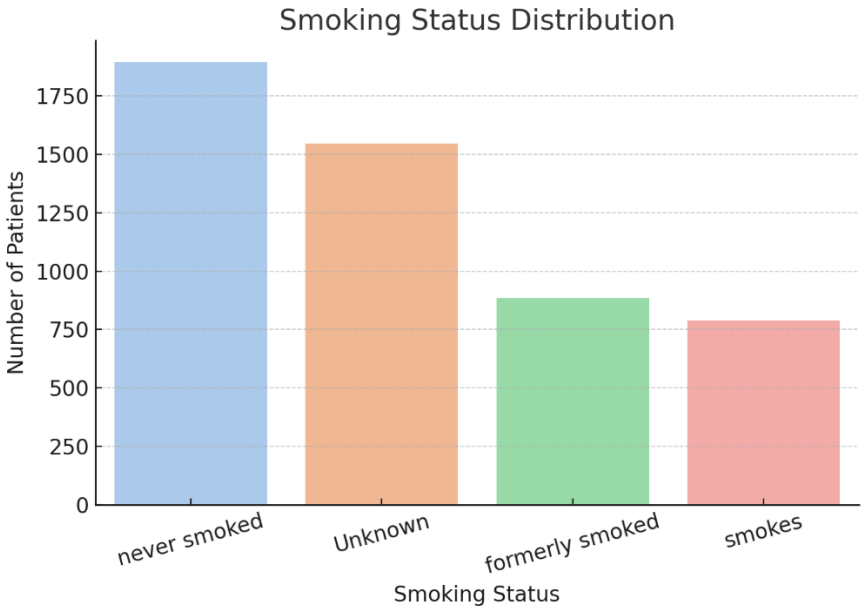

4) **שיעור שבץ באוכלוסייה (Pie chart)**
מדגיש את חוסר האיזון בין המקרים — רק כ־5% לקו בשבץ.

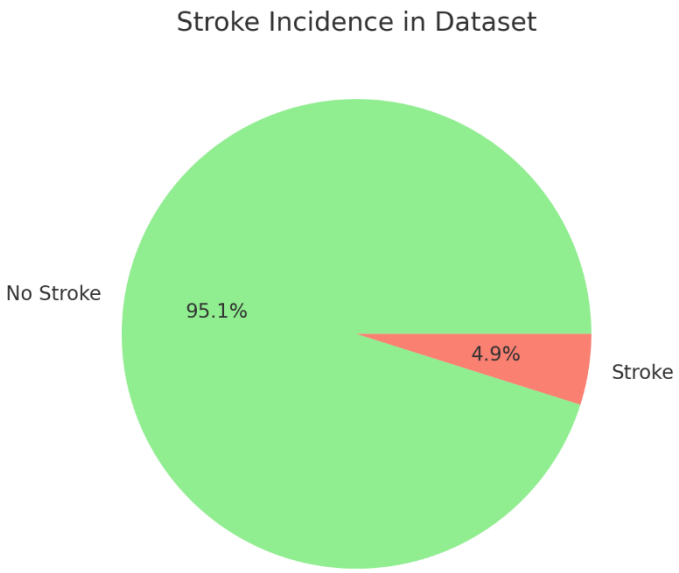

5) תרשים מתאם בין תכונות מספריות שונות לבין תכונת המטרה (stroke) המדגים קשרים חזקים או חלשים בין משתנים.

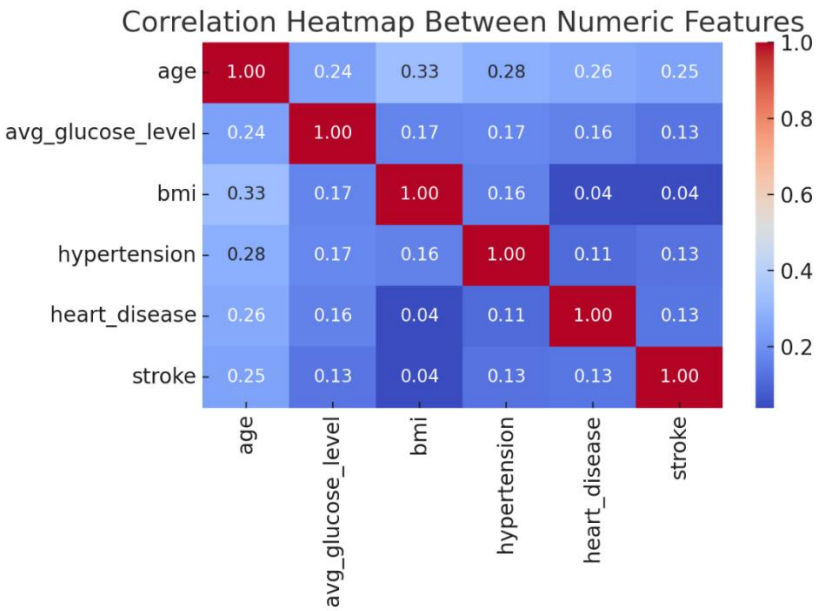

היסטוגרמות המציגות את ההתפלגות של כל אחת מהתכונות שהשתמשנו בהן:

- תכונות מספריות ונירמליות:

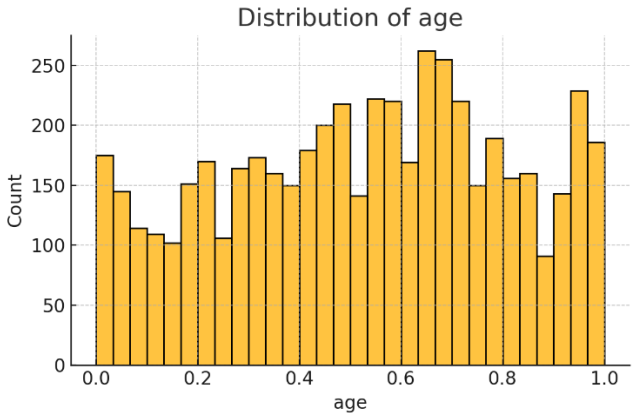

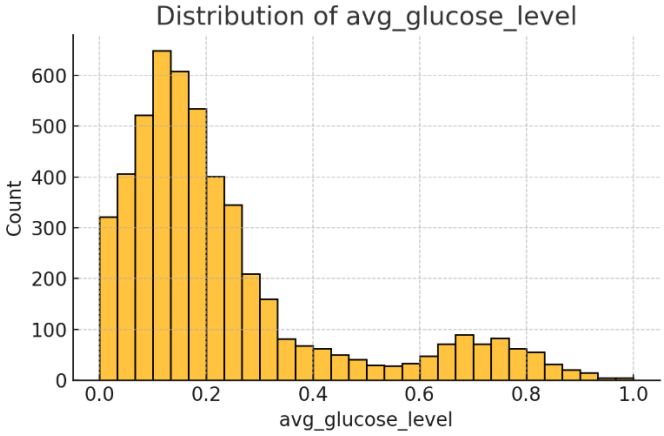

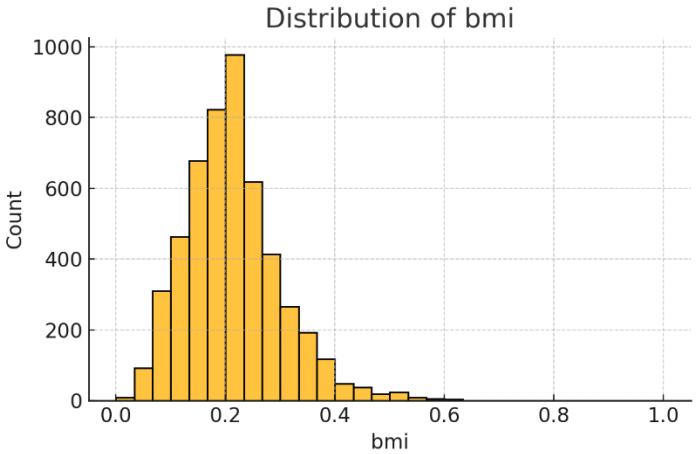

- תכונות בריאותיות ובינאריות:

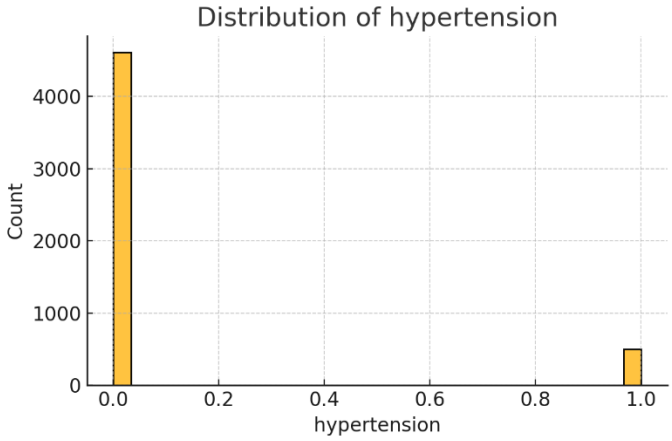

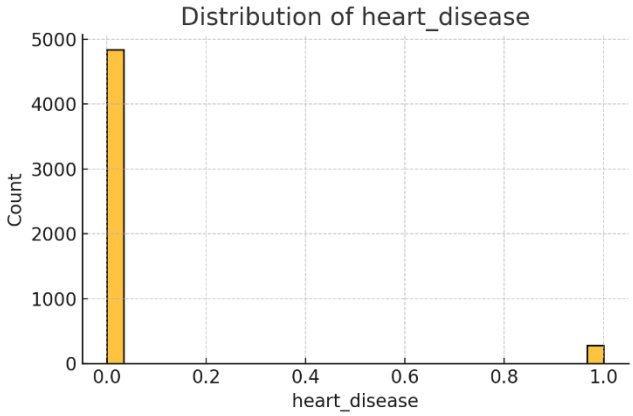

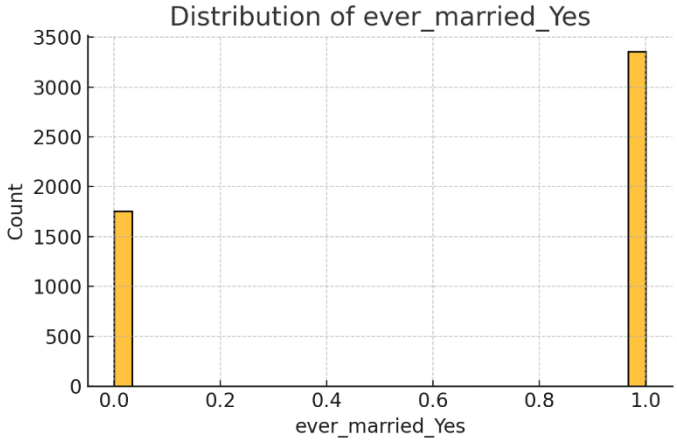

תרשים: התפלגות משתנה אינטראקציה בין מחלת לב לגיל מבוגר (heart_senior_interaction)

המשתנה heart_senior_interaction נוצר כחלק מהנדסת התכונות, והוא מבטא את האינטראקציה בין שני משתנים בינאריים heart_disease :(קיום מחלת לב) ו־ is_senior (גיל מעל 60). ערך 1 מציין נבדקים עם מחלת לב אשר מוגדרים גם כקשישים, בעוד שערך 0 מציין את שאר הנבדקים. מתוך כלל הדגימות, ניתן לראות שמספר הנבדקים עם אינטראקציה זו קטן יחסית, אך ייתכן שהיא נשאית מידע חיזויי משמעותי עבור סיכון לשבץ.

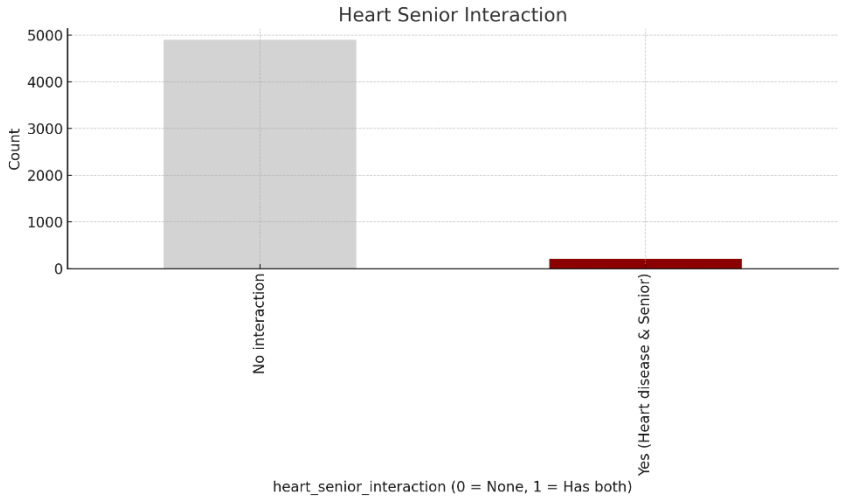

- תכונות דמוגרפיות מקודדות:

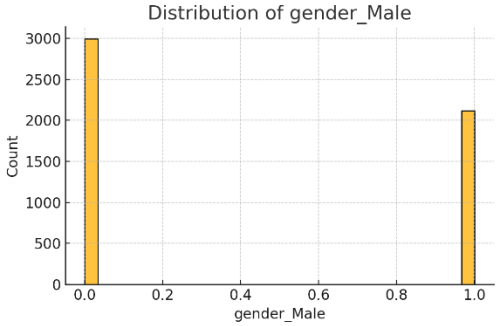

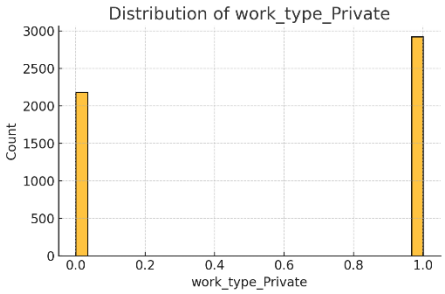

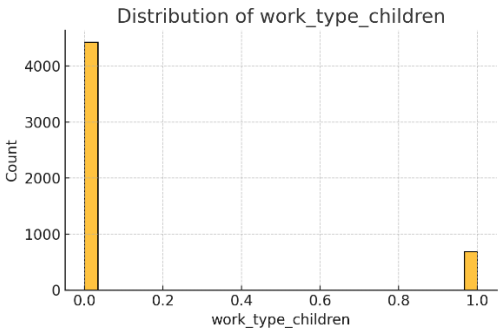

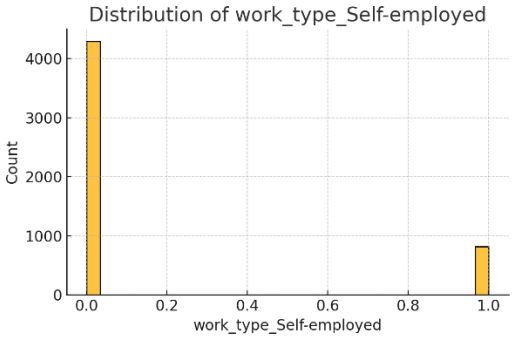

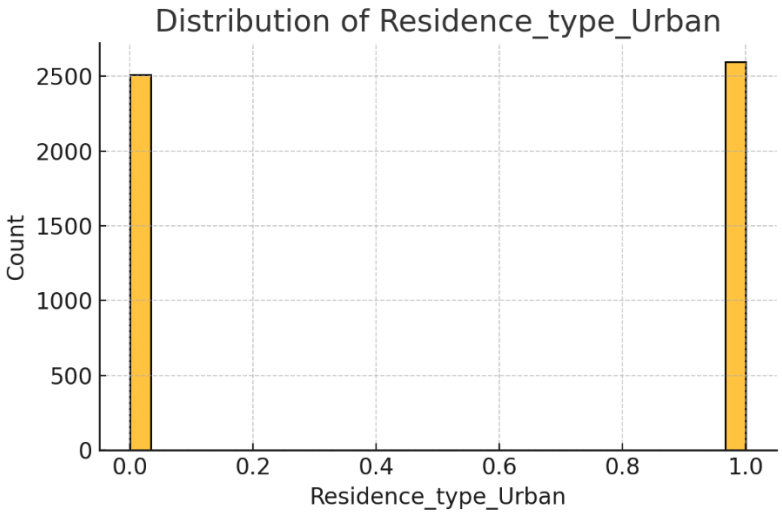

- תכונות עישון:

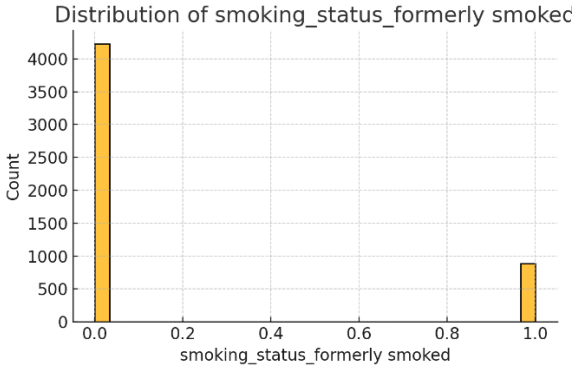

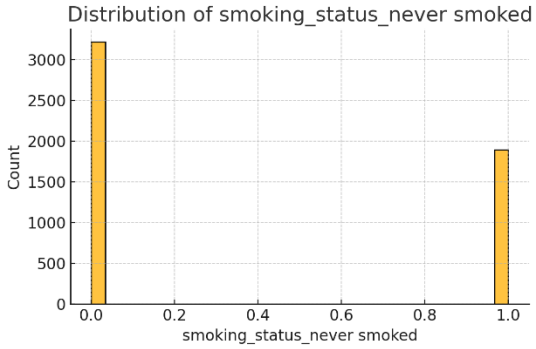

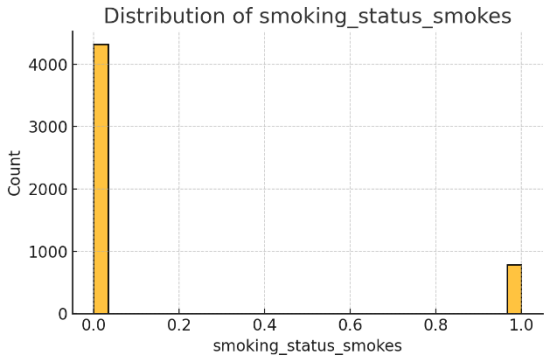

- עמודת המטרה:

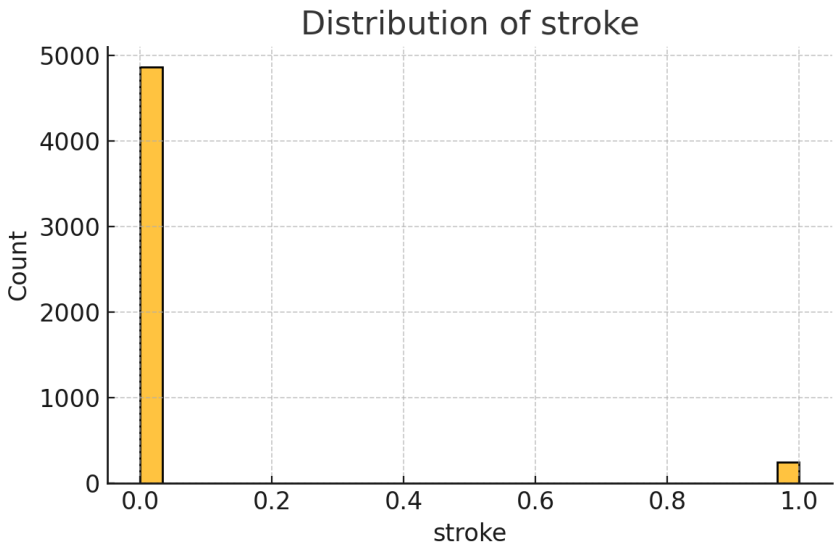

רשימת התכונות הסופית:

התכונה	סוג תכונה (לפני קידוד)	סוג תכונה (אחרי קידוד)	תחום ערכים	שיטת טיפול	ממוצע	סטיית תקן
age	רציפה	רציפה	[0–1]	נירמול Min-Max	0.5267	0.2760
avg_glucose_level	רציפה	רציפה	[0–1]	נירמול Min-Max	0.2355	0.2091
bmi	רציפה	רציפה	[0–1]	השלמת ערכים חסרים + נירמול Min-Max	0.2130	0.0882
hypertension	בינארית	בינארית	[0–1]	הושארה כמות שהיא	0.0975	0.2966
heart_disease	בינארית	בינארית	[0–1]	הושארה כמות שהיא	0.0540	0.2261
ever_married_Yes	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot	0.7352	0.4411
gender_Male	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot + הסרת ערך ""Other	0.5747	0.4944
work_type_Private	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot	0.6562	0.4751
work_type_Self-employed	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot	0.1584	0.3651
work_type_children	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot	0.0665	0.2492
Residence_type_Urban	קטגוריאלית	בינארית (One-Hot)	[0–1]	קידוד One-Hot	0.4987	0.5000
smoking_status_formerly smoked	קטגוריאלית	בינארית (One-Hot)	[0–1]	השלמת ערכים חסרים + קידוד One-Hot	0.1674	0.3732
smoking_status_never smoked	קטגוריאלית	בינארית (One-Hot)	[0–1]	השלמת ערכים חסרים + קידוד One-Hot	0.5749	0.4944
smoking_status_smokes	קטגוריאלית	בינארית (One-Hot)	[0–1]	השלמת ערכים חסרים + קידוד One-Hot	0.1577	0.3645
glucose_bmi_ratio	רציפה	רציפה	[0–1]	יצירה חדשה + נירמול Min-Max	0.0897	0.0609
glucose_age_ratio	רציפה	רציפה	[0–1]	יצירה חדשה + נירמול Min-Max	0.0054	0.0041
bmi_age_product	רציפה	רציפה	[0–1]	יצירה חדשה + נירמול Min-Max	0.2855	0.1484
age_hypertension	רציפה × בינארית	רציפה	[0–1]	יצירה חדשה + נירמול Min-Max	0.0544	0.1197
is_senior	בינארית (נגזרת מ-age)	בינארית	{0,1}	חישוב לפי גיל > 60	0.2132	0.4098

heart_senior_interaction	בינארית × בינארית	בינארית	{0,1}	אינטראקציה בין מחלת לב וגיל מבוגר	0.0131	0.1136
bmi_hypertension	רציפה × בינארית	רציפה	[0–1]	יצירה חדשה על בסיס bmi ו- hypertension	0.261	0.196
age_squared	רציפה	רציפה	[0–1]	חישוב ריבוע גיל (age^2) ולאחר מכן נירמול	0.200	0.215
glucose_heart	רציפה × בינארית	רציפה	[0–1]	אינטראקציה בין avg_glucose_level למחלת לב	0.158	0.167
smoke_age_interaction	רציפה × רציפה	רציפה	[0–1]	אינטראקציה בין גיל לשכיחות עישון	0.330	0.187

שאלה 2: סיווג

א. בחירת שיטות סיווג והסבר הבחירה

בשלב הסיווג בחרתי בשתי שיטות שונות מבחינה מבנית ומעשית לצורך השוואה:

1) **Decision Tree (C4.5)**

- זוהי שיטה היררכית שמתבסס על חלוקה סדרתית של הנתונים לפי תכונות משמעותיות.
- השיטה יוצרת עץ קל לפרשנות, שבו כל צומת מייצג שאלה על אחת התכונות.
- אחת הסיבות העיקריות לבחירה בשיטה זו היא **היכולת להסביר את ההחלטות המתקבלות** – תכונה חשובה מאוד בתחום הרפואי.
- השימוש במדד Gain Ratio מאפשר להתמודד עם תכונות בעלות מספר רב של ערכים.

2) **Random Forest**

- מדובר באנסמבל של עצי החלטה, כאשר כל עץ נבנה על תת־קבוצה אקראית של התכונות והדגימות.
- השיטה מבוססת על **הצבעה של העצים** (bagging) דבר שמפחית סיכון ל־overfitting .
- נבחרה בשל **ביצועים גבוהים במיוחד** בתחום של חיזוי רפואי, ובמיוחד במצבים של חוסר איזון בין מחלקות (כמו במקרה של stroke = 1 מול stroke = 0).
- לשיטה זו יתרון ביכולת להעריך את **חשיבות התכונות** באופן אוטומטי.

סיכום הבחירה:

בחרתי בשתי שיטות אשר מצד אחד שונות זו מזו בגישת הסיווג (עץ בודד לעומת אנסמבל), ומצד שני מותאמות היטב לסוג הנתונים והבעיה (class imbalance, תכונות מגוונות, צורך בפרשנות רפואית).

שילובן יאפשר גם השוואה בין **מודל פרשני** לבין **מודל מדויק יותר אך פחות שקוף**.

ב. פסאודו-קוד עבור כל אחד מהשיטות שבחרתי:

להלן פסאודו־קוד עבור שתי השיטות שנבחרו Decision Tree (C4.5) ו־Random Forest במטרה לתאר בצורה כללית ומובנת את אופן פעולת האלגוריתם, מבלי להיכנס לקוד בפועל:

פסאודו-קוד - Decision Tree (C4.5):

```
Input:
  D – training dataset
  T – minimum number of samples to split a node

Function BuildTree(D):
  1. If all samples in D belong to the same class:
       Return a leaf node with that class
  2. If no attributes remain or |D| < T:
       Return a leaf node with the majority class in D
  3. Else:
     a. For each attribute A:
          Compute GainRatio(D, A)
     b. Select attribute A_best with highest GainRatio
     c. Split D into subsets {D1, D2, ..., Dk} based on A_best
     d. For each subset Di:
          Child_i ← BuildTree(Di)
     e. Return a node with A_best as decision attribute and {Child_i} as subtrees
```

הסבר:

אלגוריתם עץ החלטה פועל לפי עקרון של חלוקה הדרגתית של הדאטה לצמתים בהתאם לתכונה "הכי טובה" בכל שלב.

בפסאודוקוד שהוצג:

- השלב הראשון בודק אם כל הדוגמאות שייכות לאותה מחלקה – במצב כזה נוצר עלה שמייצג את המחלקה הזו.
- אם לא – מחפשים את התכונה שמחלקת הכי טוב את הנתונים לפי מדד Gain Ratio , שהוא שיפור על מידע הדדי (Information Gain) ומתחשב גם במספר הערכים האפשריים של כל תכונה.
- הנתונים מפוצלים לפי ערכי התכונה הזו, והאלגוריתם קורא לעצמו שוב על כל תת־קבוצה.

- בסופו של תהליך, נבנה עץ החלטה שלם שבו כל מסלול מוביל למחלקה חזויה.

היתרון המרכזי של השיטה הזו הוא פרשנות גבוהה – ניתן לעקוב אחרי ההחלטות של המודל, דבר שהוא חשוב במיוחד בתחומים רגישים כמו רפואה.

פסאודו־קוד – Random Forest:

```
Input:
  D – training dataset
  N – number of trees to build
  F – number of random features to consider at each split

Function TrainRandomForest(D, N, F):
  For i = 1 to N:
    1. Draw bootstrap sample Di from D
    2. Build decision tree Ti using Di:
      a. At each node:
        - Randomly select F features
        - Choose best split among those features
      b. Repeat recursively until stopping condition met
    3. Add tree Ti to the forest

Function PredictWithForest(x, Forest):
  1. For each tree Ti in Forest:
       Predict class label ci for x
  2. Return the majority vote class among {c1, c2, ..., cN}
```

הסבר:

Random Forest היא שיטה מבוססת אנסמבל (Ensemble Learning) שבה נבנים עצי החלטה רבים, וכל אחד מהם מקבל גרסה מעט שונה של הנתונים:

- בפסאודוקוד, בכל איטרציה נלקחת דגימה אקראית עם החזרה (bootstrap) מהדאטה המקורית, על מנת לבנות עץ חדש.
- בכל צומת בתוך כל עץ, נבחרת תת־קבוצה אקראית של תכונות (feature subsampling) ומתוכה נבחרת התכונה עם הביצוע הטוב ביותר (למשל לפי Gini או Gain).

- כל עץ נבנה עד עומק מסוים או עד תנאי עצירה.
- בסופו של דבר, התחזית ניתנת על ידי **הצבעה רובית** בין כל העצים שנבנו – מה שמאפשר תוצאה יציבה ומאוזנת.

היתרון המרכזי של השיטה הזו הוא ביצועים גבוהים ועמידות לרעש בנתונים. היא מתאימה מאוד לבעיות שבהן יש חוסר איזון בין מחלקות – כמו במקרה של חיזוי שבץ, שבו כ־5% מהתצפיות הן positive .

ג. תוצאות הניתוחים עבור כל שיטה:

לפני הצגת התוצאות, להלן הפרמטרים ששימשו להרצת כל אחת מהשיטות ,בהתאם למימוש בקוד:

Decision Tree (באמצעות DecisionTreeClassifier):

- max_depth=4 להגבלת עומק העץ ומניעת overfitting.
- min_samples_leaf=40 כדי להבטיח שכל עלה יכיל לפחות 40 תצפיות.
- class_weight='balanced' לאיזון מלאכותי של המחלקות.
- criterion='entropy' למדידת איכות הפיצול על בסיס אינפורמציה.
- random_state=42 לקביעות בתוצאות.

טבלת ביצועים:

```
=== Detailed Classification Report for Decision Tree ===
Class      TP Rate   FP Rate   Precision   Recall    F-Measure   MCC       ROC Area  PRC Area
-----------------------------------------------------------------------------------------------
No         0.891     0.023     0.977       0.891     0.932       0.312     0.185     0.908
Yes        0.600     0.779     0.221       0.600     0.323       0.312     0.815     0.171
Weighted Avg.0.877     0.060     0.940       0.877     0.902       0.312     0.815     0.171
```

```
[[866 106]
 [ 20  30]]
Correctly Classified Instances: 896 (87.67%)
Incorrectly Classified Instances: 126 (12.33%)
Specificity: 0.891
```

הפרמטרים ששימשו להרצה עבור:

Random Forest (באמצעות RandomForestClassifier):

- n_estimators=150 – מספר העצים באנסמבל.
- min_samples_leaf=2 – כל עלה יכיל לפחות שתי דגימות.
- class_weight={0:1, 1:3} – משקל מוגבר למחלקת stroke.
- random_state=42 – עקביות בריצות חוזרות.

טבלת ביצועים:

```
=== Detailed Classification Report for Random Forest ===
Class      TP Rate   FP Rate   Precision   Recall    F-Measure   MCC       ROC Area  PRC Area
-----------------------------------------------------------------------------------------
No         0.843     0.023     0.977       0.843     0.905       0.260     0.188     0.899
Yes        0.620     0.832     0.168       0.620     0.265       0.260     0.812     0.170
Weighted Avg.0.832     0.062     0.938       0.832     0.874       0.260     0.812     0.170
```

```
Correctly Classified Instances: 850 (83.17%)
Incorrectly Classified Instances: 172 (16.83%)

Confusion Matrix:
[[819 153]
 [ 19  31]]
Specificity: 0.843
```

```
=== סעיף 2.ג: מדדי ביצוע עבור כל שיטה ===
Model              Threshold Accuracy  Precision   Recall    F1 Score  ROC AUC
-----------------------------------------------------------------------------
Decision Tree      N/A       0.877     0.94        0.877     0.902     0.815
Random Forest      0.32      0.832     0.938       0.832     0.874     0.812
```

תהליך אימון ובחינה:

- הנתונים חולקו ל־80% לאימון ו־20% לבדיקה, עם שמירה על שיעור המחלקות (stratify=y) .
- על סט האימון בלבד בוצע SMOTETomek להגדלת מיעוט המחלקה (stroke=1) באופן סינתטי.
- המודלים אומנו על סט האימון, ונבחנה ביצועתם על סט הבדיקה בלבד.

המדדים המשמעותיים שנבדקו:

- Accuracy - שיעור החיזויים הנכונים הכולל.
- Precision - דיוק הסיווג למחלקת השבץ.

- Recall - יכולת גילוי מקרי שבץ בפועל.
- F1 Score - ממוצע הרמוני בין Precision ל־Recall.
- ROC AUC - שטח תחת עקומת ה־ ROC , מייצג את איכות ההפרדה הכללית בין המחלקות (מצורף גרף בהמשך).

תצוגה גרפית של עץ ההחלטה שנוצר בתהליך האימון:

התרשים שלפנינו מציג את עץ ההחלטה שנבנה במהלך אימון המודל מסוג DecisionTreeClassifier תוך שימוש ב־15 התכונות שנבחרו לפי מידע הדדי (mutual information) גבוה ביותר.

המודל אומן על סט אימון שעבר איזון באמצעות SMOTETomek , לאחר תהליך מקדים שכלל: הסרת ערכים חריגים, השלמת ערכים חסרים, נירמול תכונות רציפות, קידוד תכונות קטגוריאליות, והפקת תכונות חדשות באמצעות Feature Engineering .

מאפיינים טכניים של העץ:

- **criterion**: 'entropy' – מדד לבחירת פיצולים על בסיס אינפורמציה.
- **max_depth**: 4 – הגבלה לעומק מקסימלי למניעת overfitting.
- **min_samples_leaf**: 40 – על כל עלה לכלול לפחות 40 תצפיות.
- **class_weight**: 'balanced' – לאיזון מלאכותי בין מחלקות.

מאפיינים מבניים של העץ:

- **עומק מרבי בפועל** :4
- **מספר צמתים כולל** :33
- **מספר עלים סופיים** :17
- **תוויות הסיווג :** Stroke, No Stroke

התכונות ששימשו בפיצולים בעץ בפועל כוללות:

- age_squared - ריבוע הגיל, מופיע בשורש העץ.
- glucose_age_ratio - יחס בין גלוקוז לגיל.
- work_type_freq - קידוד לפי שכיחות סוג העבודה.
- bmi_age_product - מכפלת BMI בגיל.
- avg_glucose_level - רמת סוכר ממוצעת.
- smoke_age_interaction - אינטראקציה בין גיל להרגלי עישון.

תכונות אלו נבחרו בעקבות ערכן הגבוה במדד mutual information ונועדו לחשוף דפוסים מורכבים המעידים על סיכון לשבץ.

התרשים הופק באמצעות plot_tree() מספריית sklearn.tree ומציג:

- את **מדד האנטרופיה בכל צומת** (Entropy)
- את **מספר הדגימות שהגיעו לצומת**

- את **התפלגות התצפיות בין מחלקות stroke=0 ו־stroke=1**
- את **התווית החזויה (class)** בכל עלה סופי

עץ מסוג זה מספק לא רק מודל קבלת החלטות שקוף ובר־פרשנות, אלא גם בסיס למודלים מרובי עצים כמו Random Forestשמבצעים ממוצע על פני עצים רבים ומביאים לדיוק משופר על חשבון שקיפות.

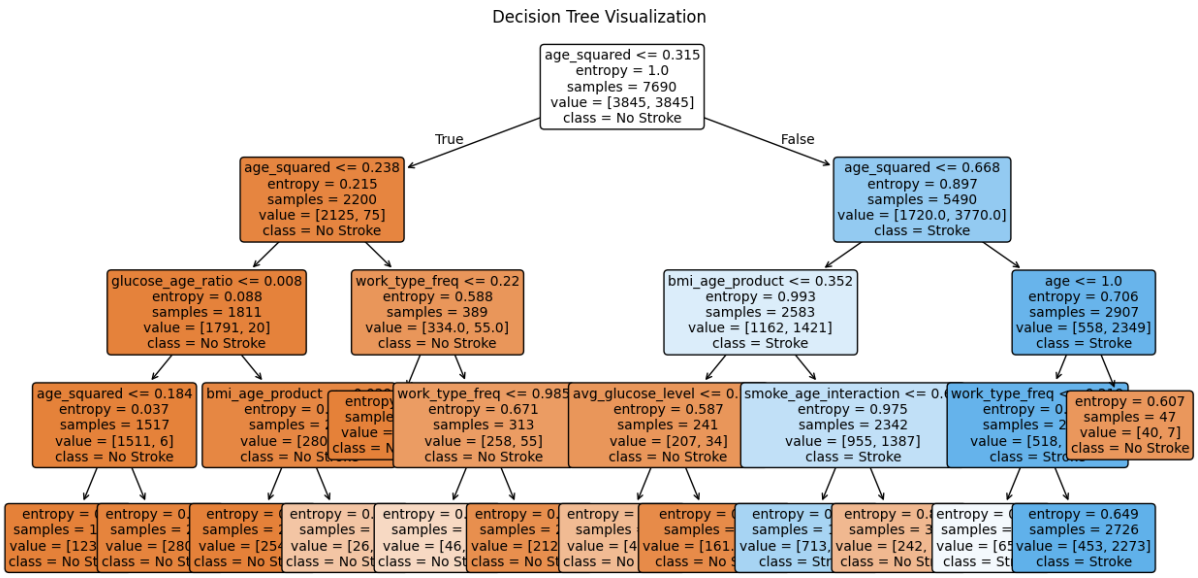

תרשים: עקומת – ROC השוואה בין המודלים Decision Tree ו־Random Forest
התרשים מציג את עקומות ה־ ROC של שני מודלים שנבחנו לצורך חיזוי שבץ:

- הקו הכתום מייצג את מודל **Random Forest** עם שטח תחת העקומה (ROC AUC) של **0.812**.
- הקו הירוק מייצג את מודל **Decision Tree** עם ROC AUC של – **0.815** מעט גבוה יותר.

שני המודלים עברו את סף הדיוק שנדרש (AUC ≥ 0.8) והם מציגים יכולת הפרדה טובה בין חולים ללא־חולים. ההבדלים הקלים בין המודלים מצביעים על כך ש־ Decision Tree מציע שקיפות גבוהה לצד ביצועים טובים, בעוד ש־ Random Forest מספק יציבות וביצועים כלליים חזקים – אך בפרשנות נמוכה יותר.

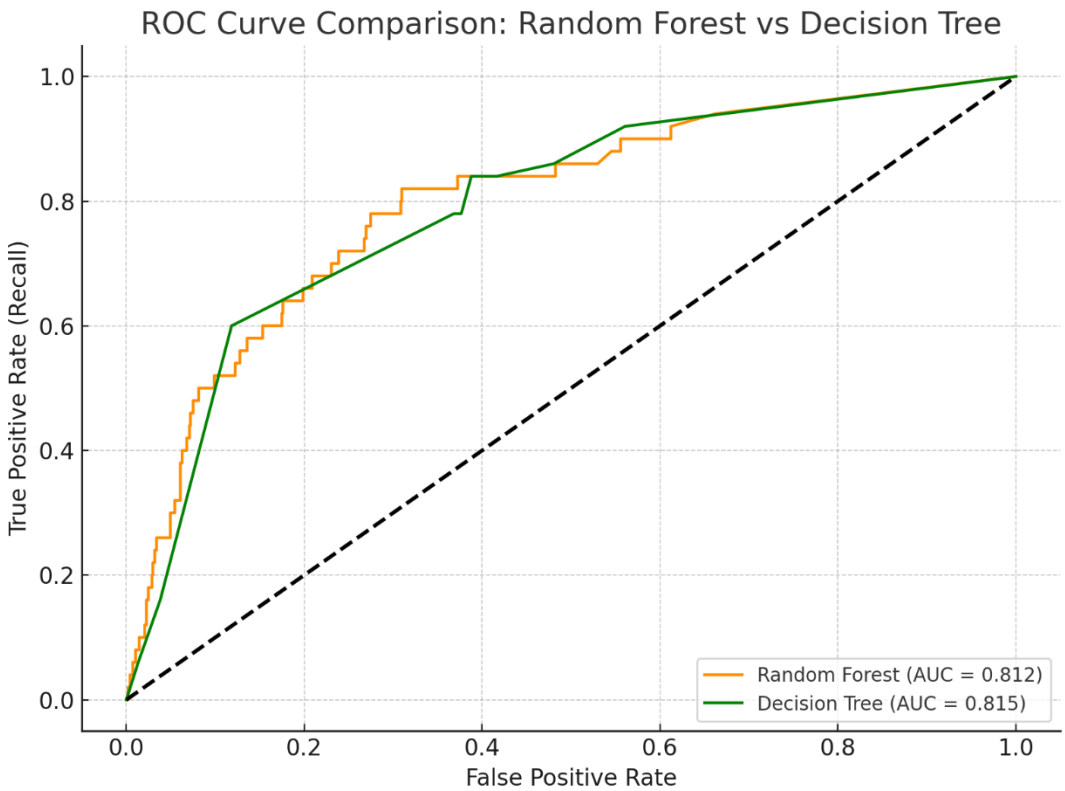

ד. +ה. הערכת מידת הדיוק וניתוח השוואתי ומסקנות כולל הצעות לשיפור:

```
=== סעיף 2.ד: ממוצע משוקלל של המדדים (Weighted Avg) ===
Model              Precision   Recall    F1 Score  ROC AUC
-------------------------------------------------------------
Decision Tree      0.94        0.877     0.902     0.815
Random Forest      0.938       0.832     0.874     0.812
```

הטבלה הבאה מציגה השוואה בין ביצועי שני המודלים:

מדד ביצוע	Decision Tree	Random Forest
דיוק (Accuracy)	87.7%	83.2%
Percision	94%	93.8%
Recall (stroke=1)	60.0%	62.0%
ROC Area (AUC)	81.5%	81.2%
False Negatives	20	19
פרשנות	גבוהה מאוד	בינונית
עמידות לרעש	בינונית	גבוהה מאוד

מסקנות עיקריות:

- ❖ שני המודלים שנבחנו עומדים בדרישות הסף שנקבעו: Precision, Recall, Accuracy ו־ROC AUC – כולם עברו את ערך הסף של 0.8 בממוצע המשוקלל.
- ❖ מודל Decision Tree בלט בדיוק הכללי (87.7%) וב־Precision (0.94), תוך שמירה על מספר False Negatives נמוך (20 בלבד) – תוצאה המצביעה על זיהוי מדויק של חולי שבץ, תוך הבטחת פרשנות שקופה.
- ❖ מודל Random Forest סיפק Recall מעט גבוה יותר (62% לעומת 60%), מה שמעיד על רגישות משופרת לזיהוי חולים, אך במחיר של ירידה מסוימת ב־Precision – מה שעלול להוביל ליותר התראות שווא.
- ❖ מהיבט ההסבריות (explainability), עץ ההחלטה מציע יתרון ברור – תכונה קריטית בסביבה קלינית שבה יש צורך להבין ולהצדיק תחזיות רפואיות.

הצעות לשיפור עתידי של המודלים והתהליך:

1. שיפור איזון המחלקות:
   - ❖ לצד SMOTETomek, ניתן לבחון שימוש ב־ADASYN או ב־class_weight מותאם.
   - ❖ למידה רגישת־עלות (Cost-sensitive learning) עשויה להפחית False Negatives.
2. העשרת תכונות:
   - ❖ יצירת אינטראקציות נוספות (כגון hypertension × bmi, עישון × גיל).
   - ❖ דיסקרטיזציה של גיל לקבוצות עשויה לחשוף תבניות חדשות.
3. שיפור האלגוריתמים:
   - ❖ בחינת Gradient Boosting, XGBoost או LightGBM.
   - ❖ כוונון פרמטרים באמצעות GridSearchCV או RandomizedSearchCV.
4. שיטות הערכה מתקדמות:
   - ❖ k-fold Cross-Validation לצמצום השפעת חלוקות מקריות.
   - ❖ ניתוח ביצועים לפי קבוצות (מין, גיל) לצורך גילוי הטיות.
5. שיפור שימוש קליני:

- הוספת נתונים רפואיים נוספים: תרופות, היסטוריה משפחתית.
- שילוב Explainable AI (כגון SHAP) להצגת נימוקים לתחזית.

לסיכום:

שני המודלים עומדים בדרישות הקורס ומשיגים תוצאות חיזוי מרשימות.

מודל Decision Tree מצטיין בדיוק, שקיפות ומספר False Negatives נמוך – מה שהופך אותו לאידיאלי לשימוש במערכות קליניות הדורשות הסבריות.

לעומתו, Random Forest מצטיין ב־Recall גבוה יותר ועמידות לרעש – ולכן עשוי להתאים יותר למצבים בהם חשוב שלא לפספס מקרים גם במחיר של יותר התראות שווא.

מומלץ לשקול גישה היברידית: שימוש ב־Random Forest לצורך חיזוי מדויק, וב־Decision Tree ככלי נלווה להסבר תחזיות, על מנת לשלב בין ביצועים לפרשנות – במיוחד כאשר התוצאה משמשת להחלטות רפואיות קריטיות.

הבחירה בין המודלים תלויה בקונטקסט הקליני: במצבים בהם נדרשת פרשנות ברורה Decision Tree – עדיף; במצבים בהם נדרש איתור מקסימלי של חולים Random Forest – יוביל.