פתרון לממ"ן 22 – פרויקט גמר בקורס כריית מידע 20595

שם: לינוי ביטון

ת.ז: 211589775

שאלה 1 – חוקי הקשר:

א. בחירת אלגוריתם – Apriori

לשלב של כריית חוקי הקשר בפרויקט זה בחרתי להשתמש באלגוריתם Apriori, מכיוון שהוא מתאים במיוחד לניתוח קשרים תבניתיים בין תכונות דיסקרטיות. מדובר באלגוריתם קלאסי ופשוט יחסית להבנה, שמאפשר לאתר קבוצות פריטים שכיחות (frequent itemsets) על בסיס סף תמיכה מוגדר מראש, ומהן לגזור חוקי הקשר מבוססי סף בטחון.

הבחירה ב־Apriori נבעה גם מהמבנה של מסד הנתונים בו אני משתמשת, המבוסס על נתונים קליניים, דמוגרפיים והרגלים של מטופלים (למשל: מין, גיל, לחץ דם, עישון, סוג תעסוקה, מצב סוכרת וכו'), אשר רובם כבר מקודדים או עברו דיסקרטיזציה מוקדמת בעבודתי בממן 21. האלגוריתם מסוגל להתמודד היטב עם מידע כזה – שבו מעניין לבדוק אילו תכונות נוטות להופיע יחד עם תכונת היעד stroke, גם כאשר אין בהכרח קשר סיבתי מובהק אלא קשר סטטיסטי שחוזר על עצמו.

בנוסף, אחד היתרונות הבולטים של Apriori הוא השקיפות שלו: ניתן להסביר בצורה ברורה אילו חוקים התקבלו, מה מידת התמיכה והביטחון שלהם, ולהיעזר ב־lift כדי להבין אם יש תלות אמיתית או לא. בכך הוא שונה מהמודלים שבהם השתמשתי בממ"ן 21 (Decision Tree ו־Random Forest), שמתמקדים בחיזוי התוצאה אך פחות חושפים את הקשרים הפנימיים בין משתנים. עם זאת, יש לקחת בחשבון כי ביצועי האלגוריתם עלולים להיות מושפעים ממידת ריבוי הפריטים ומהצורך בעיבוד מקדים נרחב של הנתונים.

לסיכום, הבחירה ב־Apriori תומכת בהבנה עמוקה יותר של הדאטה הרפואי – לא רק לצורך חיזוי, אלא גם כדי לזהות דפוסים חוזרים שיכולים לסייע לאנשי מקצוע במניעה וגילוי מוקדם של שבץ.

ב. + **ד.**

בשלב זה ביצעתי הכנה של הנתונים לצורך הפעלת אלגוריתם Apriori, בהתבסס על עקרונות ממ"ן 21, תוך הקפדה על ניקוי וסידור הנתונים: הסרתי ערכים חריגים מהעמודה gender (סינון הערך 'Other'), השלמתי ערכים חסרים ב־bmi באמצעות ממוצע האוכלוסייה, ומילאתי ערכים חסרים ב־smoking_status בערך 'Unknown', כדי לשמר הבחנה בין נבדקים שהמידע עליהם חסר לבין כאלה שלא עישנו מעולם.
כיוון ש־Apriori דורש קלט בינארי, בוצעה דיסקרטיזציה לתכונות רציפות כגון age, bmi ו־avg_glucose_level, תוך חלוקתן לקבוצות קטגוריאליות (למשל: Young, Adult, Mid-age, Old). בנוסף, יצרתי משתנים בינאריים בעלי משמעות קלינית כמו is_old (גיל מעל 60), high_glucose, high_bmi, married_old (נשואים בגיל מבוגר), ו־urban_and_private (מגורים עירוניים ותעסוקה פרטית).
בנוסף, ביצעתי קידוד One-Hot לכל התכונות הקטגוריאליות וביאניזציה לכל העמודות לצורך הפעלת האלגוריתם.
בנוסף לדיסקרטיזציה שבוצעה לתכונות רציפות (age, bmi, avg_glucose_level), מיזגתי את הקטגוריות הקיימות לעמודות חדשות כמו age_group_merged, bmi_group_merged, glucose_group_merged ו־ תוך שמירה על המידע המקורי.
כללתי שלב מתקדם של מיזוג קבוצות קליניות חלשות לקטגוריות חדשות, במטרה לפשט את הקבוצות התדירות ואת מרחב החוקים ולהפוך את החוקים המתקבלים לרלוונטיים וקליניים יותר:

- המרה של קבוצות BMI לקטגוריות משולבות: "Underweight" ו-"Normal" אוחדו כ־Low/Normal, ואילו "Overweight" ו-"Obese" אוחדו ל־High.
- המרה של רמות גלוקוז: "High" ו־"Very High" אוחדו ל־High לצורך ייצוב הקטגוריות.
- קבוצות גיל "Mid-age" ו־"Old" אוחדו לקבוצה קלינית רלוונטית בשם plus60.

מעבר לכך, יצרתי משתנים בינאריים חכמים בעלי משמעות קלינית מורחבת כמו:
- is_old – האם גיל הנבדק מעל 60.
- high_glucose – רמות גלוקוז מעל 140.
- high_bmi – BMI מעל 30.
- married_old – נבדקים מעל גיל 60 שהם גם נשואים.
- urban_and_private – שילוב של מגורים עירוניים עם עבודה במגזר הפרטי.

הרצת Apriori על כלל האוכלוסייה:
הפעלתי את אלגוריתם Apriori על כלל הדאטה, עם סף תמיכה , min_support = 0.4 min_confidence=0.6. להלן עיקרי התוצאות:

קבוצות בגודל 1 (L1):
נמצאו 11 קבוצות תדירות בגודל 1. בין השכיחות ביותר:
- bmi_group_merged_High – שכיחות 0.6856
- age_group_merged_60plus – שכיחות 0.4878
- glucose_group_merged_Low – שכיחות 0.4707
- hypertension_str_no_hypertension – שכיחות 0.9025
- heart_disease_str_no_heart_disease – שכיחות 0.9459
- ever_married_Yes, gender_Female, work_type_Private גם הופיעו בשכיחויות גבוהות יחסית

פירוש: התפלגות תכונות כלליות (כמו מגדר ומצב משפחתי) משתקפת בפלט. מרבית האוכלוסייה אינה סובלת ממחלות רקע, אך משתנים כמו BMI גבוה וגיל 60+ עדיין בולטים.

קבוצות בגודל 2 (L2):
נמצאו 22 קבוצות בגודל 2, ביניהן:
- bmi_high + no_heart_disease – שכיחות 0.6389
- bmi_high + no_hypertension – שכיחות 0.5997
- no_heart_disease + no_hypertension – שכיחות 0.8610
- ever_married_Yes + work_type_Private – שכיחות 0.4118
- age_60plus + no_heart_disease – שכיחות 0.4353

פירוש: מופיעים שילובים מגוונים – קליניים וכלליים כאחד. הקשר בין BMI גבוה והיעדר מחלות לב חוזר על עצמו.

קבוצות בגודל 3 (L3):
נמצאו 11 קבוצות תלת־משתניות, למשל:
- bmi_high + no_heart_disease + no_hypertension – שכיחות 0.5641
- gender_Female + no_heart_disease + no_hypertension – שכיחות 0.5155
- ever_married_Yes + no_heart_disease + no_hypertension – שכיחות 0.5322
- work_type_Private + no_heart_disease + no_hypertension – שכיחות 0.4940

פירוש: התוספת של משתנים כמו מין ומצב משפחתי לקבוצות התדירות מרחיבה את היכולת לגלות דפוסים כלל־אוכלוסייתיים, ולא רק קליניים.

קבוצות בגודל 4 (L4):
- נמצאה קבוצה אחת בלבד:

bmi_high + ever_married_Yes + no_heart_disease + no_hypertension – שכיחות 0.4239

מסקנות:

1. תוספת תכונות כלליות ולא רק קליניות אכן העשירה את הפלט, וחושפת קבוצות תכופות שכוללות משתנים כמו מגדר, נישואין וסוג עבודה.
2. התפלגות בריאותית חיובית בולטת – רוב הקבוצות כוללות היעדר של מחלות רקע (לב ולחץ דם).
3. BMI גבוה ממשיך להופיע בתדירות גבוהה, גם באוכלוסייה בריאה יחסית, מה שמעיד על קשר אפשרי לא־טריוויאלי בין השמנה וסיכון שבץ, גם בהיעדר מחלות אחרות.

```
L(1) - 1 קבוצות שכיחות בגודל:
                            Items  Support
                     gender_Female 0.586025
                       gender_Male 0.413975
                  ever_married_Yes 0.656293
                 work_type_Private 0.572323
              Residence_type_Rural 0.491877
              Residence_type_Urban 0.508123
             bmi_group_merged_High 0.685653
           age_group_merged_60plus 0.487767
          glucose_group_merged_Low 0.470738
  hypertension_str_no_hypertension 0.902525
heart_disease_str_no_heart_disease 0.945978
```

```
L(2) - 2 קבוצות שכיחות בגודל:
                                                        Items  Support
                     gender_Female, hypertension_str_no_hypertension 0.532002
                  gender_Female, heart_disease_str_no_heart_disease 0.563907
                                ever_married_Yes, work_type_Private 0.411822
                           bmi_group_merged_High, ever_married_Yes 0.533177
                         age_group_merged_60plus, ever_married_Yes 0.449794
                  ever_married_Yes, hypertension_str_no_hypertension 0.569192
               ever_married_Yes, heart_disease_str_no_heart_disease 0.608534
                            bmi_group_merged_High, work_type_Private 0.437072
                hypertension_str_no_hypertension, work_type_Private 0.517322
```

```
heart_disease_str_no_heart_disease, work_type_Private 0.541398
Residence_type_Rural, hypertension_str_no_hypertension 0.442748
Residence_type_Rural, heart_disease_str_no_heart_disease 0.465649
Residence_type_Urban, hypertension_str_no_hypertension 0.459777
Residence_type_Urban, heart_disease_str_no_heart_disease 0.480329
age_group_merged_60plus, bmi_group_merged_High 0.405559
bmi_group_merged_High, hypertension_str_no_hypertension 0.599726
bmi_group_merged_High, heart_disease_str_no_heart_disease 0.638873
age_group_merged_60plus, hypertension_str_no_hypertension 0.402819
age_group_merged_60plus, heart_disease_str_no_heart_disease 0.435310
glucose_group_merged_Low, hypertension_str_no_hypertension 0.436485
glucose_group_merged_Low, heart_disease_str_no_heart_disease 0.453318
heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.861030
```

L(3) - 3 קבוצות שכיחות בגודל:

```
Items  Support
gender_Female, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.515561
bmi_group_merged_High, ever_married_Yes, hypertension_str_no_hypertension 0.455862
bmi_group_merged_High, ever_married_Yes, heart_disease_str_no_heart_disease 0.491681
age_group_merged_60plus, ever_married_Yes, heart_disease_str_no_heart_disease 0.403014
ever_married_Yes, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.532198
bmi_group_merged_High, heart_disease_str_no_heart_disease, work_type_Private 0.409473
heart_disease_str_no_heart_disease, hypertension_str_no_hypertension, work_type_Private 0.494030
Residence_type_Rural, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.422979

Residence_type_Urban, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.438050
bmi_group_merged_High, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.564103
glucose_group_merged_Low, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.422979
```

L(4) - 4 קבוצות שכיחות בגודל:

```
Items  Support
bmi_group_merged_High, ever_married_Yes, heart_disease_str_no_heart_disease, hypertension_str_no_hypertension 0.423958

Size of set of large itemsets L(1): 11

Large Itemsets L(1):
gender_Female: 2994
gender_Male: 2115
ever_married_Yes: 3353
work_type_Private: 2924
Residence_type_Rural: 2513
Residence_type_Urban: 2596
bmi_group_merged_High: 3503
age_group_merged_60plus: 2492
glucose_group_merged_Low: 2405
hypertension_str_no_hypertension: 4611
heart_disease_str_no_heart_disease: 4833
```

```
Size of set of large itemsets L(2): 22

Large Itemsets L(2):
gender_Female hypertension_str_no_hypertension: 2718
gender_Female heart_disease_str_no_heart_disease: 2881
ever_married_Yes work_type_Private: 2104
bmi_group_merged_High ever_married_Yes: 2724
age_group_merged_60plus ever_married_Yes: 2298
ever_married_Yes hypertension_str_no_hypertension: 2908
ever_married_Yes heart_disease_str_no_heart_disease: 3109
bmi_group_merged_High work_type_Private: 2233
hypertension_str_no_hypertension work_type_Private: 2643
heart_disease_str_no_heart_disease work_type_Private: 2766
Residence_type_Rural hypertension_str_no_hypertension: 2262
Residence_type_Rural heart_disease_str_no_heart_disease: 2379
Residence_type_Urban hypertension_str_no_hypertension: 2349
Residence_type_Urban heart_disease_str_no_heart_disease: 2454
age_group_merged_60plus bmi_group_merged_High: 2072
bmi_group_merged_High hypertension_str_no_hypertension: 3064
bmi_group_merged_High heart_disease_str_no_heart_disease: 3264
age_group_merged_60plus hypertension_str_no_hypertension: 2058
age_group_merged_60plus heart_disease_str_no_heart_disease: 2224
glucose_group_merged_Low hypertension_str_no_hypertension: 2230
glucose_group_merged_Low heart_disease_str_no_heart_disease: 2316
heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 4399
```

```
Size of set of large itemsets L(3): 11

Large Itemsets L(3):
gender_Female heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2634
bmi_group_merged_High ever_married_Yes hypertension_str_no_hypertension: 2329
bmi_group_merged_High ever_married_Yes heart_disease_str_no_heart_disease: 2512
age_group_merged_60plus ever_married_Yes heart_disease_str_no_heart_disease: 2059
ever_married_Yes heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2719
bmi_group_merged_High heart_disease_str_no_heart_disease work_type_Private: 2092
heart_disease_str_no_heart_disease hypertension_str_no_hypertension work_type_Private: 2524
Residence_type_Rural heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2161
Residence_type_Urban heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2238
bmi_group_merged_High heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2882
glucose_group_merged_Low heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2161

Size of set of large itemsets L(4): 1

Large Itemsets L(4):
bmi_group_merged_High ever_married_Yes heart_disease_str_no_heart_disease hypertension_str_no_hypertension: 2166
```

ג. + **ד.**

הצגת חוקי הקשר החזקים:

במהלך השלב הזה הופקו 1,201 חוקי הקשר מתוך הנתונים שעברו דיסקרטיזציה, עיבוד מקדים והמרה לבינאריים, בהתבסס על האלגוריתם Apriori. מבין כלל החוקים שהתקבלו, סוננו 693 חוקים חזקים לפי תנאים סטטיסטיים מחמירים: confidence של לפחות 60%, lift מעל 1, ועמידה בסף תמיכה של לפחות 40% מהאוכלוסייה. חוקים אלו נשמרו בקובץ ייעודי, וחלקם צורפו לנספח. מתוכם, בחרתי להציג את 10 החוקים החזקים ביותר – כאלו שיש בהם משמעות קלינית, תובנה נלמדת, והם עומדים בקריטריונים של המרצה בנוגע לזיהוי תבניות שיכולות לגרום לשבץ.

ניתוח ודירוג תוצאות האלגוריתם:

בהתבסס על אלגוריתם Apriori שהופעל על תת-האוכלוסייה של חולי שבץ בלבד (stroke=1), נבחרו עשרה חוקי הקשר החזקים ביותר, תוך מתן עדיפות לחוקים שבהם עמודת המטרה stroke מופיעה ב־Consequent, עם מדדי Confidence ו־Lift גבוהים (Lift מעל 1 לפחות), עם תכונות קליניות או מהותיות – כמו גיל, מחלות רקע, BMI ומצב משפחתי – ולא רק דמוגרפיות, שמתיישבים עם המסקנות והמודלים של ממ״ן 21.

החוקים הבולטים כוללים משתנים כמו מגדר, גיל, BMI גבוה, סוג עבודה, מצב משפחתי, מגורים בעיר או בכפר – ולעיתים אף תכונות לא צפויות כמו העדר מחלות רקע (כגון לחץ דם או מחלת לב) שעדיין קשורות לשבץ דרך משתנים משולבים.

דוגמאות בולטות:

- החוק `gender_Male ⇒ age_group_merged_60plus, stroke` מצביע על כך שגברים מבוגרים נמצאים בסיכון גבוה במיוחד (Confidence = 0.926, Lift = 1.048).

- החוק `bmi_group_merged_High, is_old ⇒ married_old, stroke` מראה שברגע שמשלבים bmi גבוה וגיל מבוגר – הסיכון לשבץ עולה משמעותית (Lift = 1.42).

- החוק `hypertension_str_no_hypertension, is_old ⇒ married_old, stroke` מדגיש שגם בהיעדר יתר לחץ דם, גיל ומצב משפחתי לבדם מהווים בסיס חזק לסיכון (Lift = 1.472, Conviction = 5.13).

- החוק `Residence_type_Rural ⇒ ever_married_Yes, stroke` מציע שדווקא בסביבה כפרית, אנשים נשואים עלולים להיות בקבוצת סיכון – תובנה מעניינת שמרחיבה את הפרשנות החברתית־קלינית.

מדדים תומכים: ערכי Lift מעל 1 מעידים על קשר חזק יותר מהסתברות מקרית, Leverage חיובי מחזק את התרומה הסטטיסטית של התנאים, Conviction גבוה מצביע על נדירות של מקרים שבהם התנאי מתקיים אך stroke לא התרחש – עדות לעוצמת החוק.

המסקנות משתלבות היטב עם תובנות שהופקו בממ״ן 21, כמו החשיבות של גיל, מצב משפחתי, מחלות רקע ו־BMI גבוה במודלים של Random Forest, ומציגות בצורה שקופה ומובנת את הגורמים העיקריים לסיכון שבץ באוכלוסייה. לכן, ניתן להשתמש בחוקים אלה לבניית מערכת הסברה קלינית אינטואיטיבית, שתסייע באיתור מוקדם של קבוצות סיכון ובקבלת החלטות רפואיות על בסיס כללים מוסברים – ולא על בסיס "קופסה שחורה".

ריכזתי את ה-10 החוקים הבולטים ביותר, לפי ערך lift גבוה, מובהקות קלינית, בהם עמודת התוצאה היא stroke, חלק נכבד מהפלט המלא של 693 חוקים חזקים מצורף כנספח בסוף.

#	Antecedent	Consequent	confidence	lift	leverage	conviction	count
1	gender_Male	age_group_merged_60plus, stroke	0.926	1.048	0.018	1.572	105
2	married_old	ever_married_Yes, is_old, stroke	1.000	1.586	0.233	inf	157
3	work_type_Private	ever_married_Yes, hypertension_str_no_hypertension, stroke	0.725	1.094	0.037	1.226	108
4	bmi_group_merged_High ,is_old	married_old , stroke	0.895	1.420	0.152	3.522	128
5	age_group_merged_60plus, is_old	married_old , stroke	0.887	1.407	0.182	3.270	157
6	Residence_type_Urban, ever_married_Yes	age_group_merged_60plus, stroke	0.974	1.027	0.012	1.984	111
7	hypertension_str_no_hypertension, is_old	married_old , stroke	0.928	1.472	0.149	5.132	116
8	heart_disease_str_no_heart_disease, is_old	married_old , stroke	0.896	1.422	0.144	3.563	121
9	ever_married_Yes, married_old	Is_old, stroke	1.000	1.407	0.182	inf	157

10 6	1.660	0.02 1	1.05 2	0.930	stroke, ever_married_Yes	Residence_type_Rural	1 0

ה.

מסקנות כלליות מהתוצאות של האלגוריתם:

ניתוח קבוצות הפריטים השכיחות (Frequent Itemsets) וחוקי הקשר שנוצרו על בסיס חולי שבץ בלבד (stroke=1) מחזק באופן מובהק את המסקנות שעלו ממודלי החיזוי של ממ"ן 21, ובפרט ממודל Random Forest.

ממצאים מרכזיים מקבוצות התדירות:

- הקבוצות השכיחות בגודל 1 כוללות משתנים מרכזיים כמו: BMI גבוה (bmi_group_merged_High, תמיכה 0.685), מצב נישואין (ever_married_Yes, תמיכה 0.656), גיל מבוגר (age_group_merged_60plus, תמיכה 0.488) ומין (gender_Female – התמיכה הגבוהה ביותר, 0.586). גם היעדר מחלות רקע כמו לחץ דם או מחלת לב מופיעים עם תמיכה גבוהה מאוד – מעל 0.9.

- בקבוצות בגודל 2 ו־3, בולטים שילובים כמו:

  - bmi_group_merged_High + ever_married_Yes (תמיכה: 0.533),

  - ever_married_Yes + hypertension_str_no_hypertension (0.569),

  - bmi_group_merged_High + ever_married_Yes + heart_disease_str_no_heart_disease (0.492)

- קבוצה בגודל 4 שכללה גם BMI גבוה, גם נישואין, גם היעדר מחלות לב וגם היעדר לחץ דם – הופיעה בתמיכה של 0.424, מה שמעיד על שכיחות גבוהה של פרופיל קליני מסוים באוכלוסיית חולי השבץ.

משמעות:

שילובים תכופים אלו מצביעים על דפוס חוזר של אוכלוסיות בסיכון – בעיקר מבוגרים נשואים עם BMI גבוה, שלעתים קרובות אין להם מחלות רקע. הדפוסים האלו חופפים לדפוסים שזוהו בממ"ן 21 על ידי המודלים הסטטיסטיים, בעיקר Random Forest, שייחס משקל רב לגיל, BMI ולחץ דם.

ממצאים מחוקי ההקשר החזקים:

- חוק עם confidence של 1.0: married_old ⇒ ever_married_Yes, is_old, stroke – מדגיש סיכון מוחלט לקבוצת אוכלוסייה מאוד ממוקדת.

- חוקים כמו bmi_group_merged_High, is_old ⇒ married_old, stroke תומכים בכך ששילוב של גיל מבוגר עם BMI גבוה קשור חזק לשבץ, כפי שנמצא גם ב־Feature Importance של ממ"ן 21.

- קיומם של חוקים מפתיעים, כמו hypertension_str_no_hypertension, is_old ⇒ stroke, מראה שגם ללא מחלות רקע מובהקות, קיימת שכיחות גבוהה לשבץ בקרב מבוגרים.

השוואה לממ"ן 21:

- בממ"ן 21 נמצא כי התכונות החשובות ביותר הן age, hypertension, bmi, ו־ever_married – כולן מופיעות כחלק מהקבוצות התדירות והחוקים.

- השפעת BMI תוקפה הן ע"י הקבוצות התדירות והן ע"י החוקים – למשל, bmi_group_merged_High היה חלק מכל קבוצה עיקרית כמעט.

לסיכום, שילוב ממצאי הקבוצות השכיחות והחוקים החזקים עם מודלי ממ"ן 21 יוצר מערכת תמיכה בהחלטות חזקה, שמספקת גם תובנות פרשניות וגם חיזוי אמין. אפשר להשתמש בחוקים שנוצרו כבסיס להנחיות קליניות אינטואיטיביות – לדוגמה: "אם אדם נשוי, מבוגר ובעל BMI גבוה – הוא בקבוצת סיכון מובהקת, גם אם אין לו לחץ דם או מחלת לב כרגע".

שאלה 2 – ניתוח אשכולות:

א.

במסגרת ניתוח האשכולות שנועד לזהות קבוצות אוכלוסייה עם מאפיינים משותפים (ללא שימוש בתווית המטרה), חשוב להעריך את איכות החלוקה שהתקבלה. לשם כך, נשתמש במדדי איכות לאשכולות (Clustering Evaluation Metrics) שמודדים את מידת הדמיון בתוך כל אשכול ואת מידת ההפרדה בין אשכולות שונים.

מדדי איכות עיקריים:

1. SSE – סכום השגיאות הריבועיות (Sum of Squared Errors):

מודד את המרחק הכולל של כל נקודה במרחב ממרכז האשכול שאליו היא שויכה. ערך נמוך מצביע על כך שהנקודות קרובות למרכז האשכול – כלומר קיימת קוהרנטיות פנימית גבוהה.

2. Silhouette Coefficient (מקדם הצללית):

מדד איכות בין 0 ל־1 שמודד עד כמה כל נקודה קרובה לאשכול שלה ביחס לאשכול הקרוב הבא. ערך גבוה (קרוב ל־1) מעיד על אשכול מובהק וברר־הפרדה מהשאר.

הוא מחושב כך:

$$S(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

כאשר:

- a(i): המרחק הממוצע של נקודה i לשאר הנקודות באשכול שלה.
- b(i): המרחק הממוצע של נקודה i לנקודות באשכול הקרוב ביותר שאינו האשכול שלה.

3. Davies–Bouldin Index (DBI):

מדד שלילי שבו ערכים נמוכים יותר מצביעים על איכות אשכולות גבוהה. הוא מבוסס על יחס בין פיזור בתוך אשכול לבין מרחק בין אשכולות.

4. מדד אלבו (Elbow Method):

לא מדד כשלעצמו אלא שיטה גרפית לזיהוי מספר אשכולות מיטבי (k). משתמשים ב־SSE מול ערכי k, ומחפשים את "המרפק" שבו השיפור קטן משמעותית – כלומר: הנקודה שבה תוספת אשכולות לא משפרת משמעותית את הקומפקטיות.

נוסף על כך, חשוב להתאים את פונקציית המרחק לסוגי המשתנים שבדאטה:

עבור משתנים מספריים מקובל להשתמש במרחק אוקלידי או מנהטן, אך עבור תכונות בוליאניות או קטגוריאליות נהוג להשתמש בפונקציות מרחק מותאמות כגון Hamming או Jaccard.

לסיכום, שימוש במדדים אלה מאפשר לנו להעריך עד כמה ניתוח האשכולות מצליח להפריד בין קבוצות שונות באוכלוסייה ולזהות תבניות חבויות ללא צורך בתוויות (Unsupervised Learning). המדדים יאפשרו לנו לבחור את מספר האשכולות k האופטימלי ולהשוות בין חלופות שונות.

ב.

לניתוח האשכולות בפרויקט בחרתי באלגוריתם K-Means, אחת מהשיטות המרכזיות והנפוצות ביותר בלמידה בלתי מפוקחת. אלגוריתם זה מתאים במיוחד למקרים שבהם קיימים משתנים מספריים לאחר נירמול, כמו במקרה שלנו.

K-Means פועל על ידי חלוקת הדאטה לקבוצות (אשכולות) כך שהמרחק הממוצע בין הדגימות למרכז האשכול שלהן (centroid) יהיה מינימלי. הוא מניח מבנה כדורי לאשכולות, ולכן מתאים כאשר הנתונים לאחר נירמול מתפזרים בצורה יחסית אחידה.

נימוקים לבחירה ב-K-Means:

- הדאטה כולל מעל 4,900 תצפיות לאחר ניקוי ולכן יש צורך בשיטה יעילה ומהירה – K-Means מצטיין בסיבוכיות נמוכה יחסית ((O(nkt).

- כל התכונות בדאטה הן מספריות, ונעשו עליהן פעולות scaling לטווח אחיד – מה שמתאים לעבודה עם מרחק אוקלידי.

- האלגוריתם מאפשר שליטה במספר האשכולות מראש (k), דבר שיאפשר לקבוע את הערך האופטימלי בעזרת Elbow Method בהמשך.

- מדובר באלגוריתם שקל לפרש את תוצאותיו מבחינת מבנה האשכולות ומאפייניהם.

פסאודו-קוד של האלגוריתם K-Means:

Input:

- Dataset D עם n דגימות

- מספר אשכולות רצוי k

שלבים:

1. אתחל k מרכזי אשכולות (centroids) באופן אקראי מתוך הדגימות.
2. חזור עד להתכנסות:
   א. שייך כל דגימה לאשכול הקרוב ביותר לפי המרחק האוקלידי.
   ב. עדכן את מיקום המרכז של כל אשכול לפי ממוצע הדגימות בו.
3. החזר את שיוך הדגימות לאשכולות ואת מרכזי האשכולות.

ובאנגלית:

Algorithm: k-means. The k-means algorithm for partitioning, where each cluster’s center is represented by the mean value of the objects in the cluster.

Input:

- k: the number of clusters,
- D: a data set containing n objects.

Output:

A set of k clusters.

Method:

(1)arbitrarily choose k objects from D as the initial cluster centers;

(2)repeat

(3)(re)assign each object to the cluster to which the object is the most similar;

(4)update the cluster centers, that is, calculate the mean value of the objects for each cluster;

(5)until no change;

האלגוריתם יופעל על נתונים שעברו ניקוי ונירמול, ללא שימוש בעמודת המטרה (stroke), כדי לגלות קבוצות טבעיות באוכלוסייה. בשלב הבא יתבצע הניתוח בפועל ונפרט את ההכנות, הריצה, ובחירת k.

ג.

במסגרת ניתוח הקלאסטרינג, ביצעתי השוואה בין שני תרחישים: ניתוח עם עמודת המטרה stroke וניתוח ללא עמודת המטרה – במטרה לבדוק האם ניתן לזהות קבוצות אוכלוסייה עם סיכון גבוה לשבץ גם ללא מידע מפורש.

1. בוצעה הסרה של רשומות לא תקינות ("gender="Other"), השלמת ערכים חסרים בתכונות קליניות: עמודת bmi מולאה לפי חציון, ו־smoking_status מולאה בערך "Unknown" לצורך שמירה על הבחנה בין חוסר מידע לבין אי־עישון בפועל. בנוסף, הוסרו עמודות לא רלוונטיות לתהליך האשכולות: id, work_type, smoking_status_Unknown. בעבודה ללא stroke – עמודת המטרה הוסרה לחלוטין.
2. נוספו תכונות אינטראקטיביות שנבנו ידנית, לשם שיפור היכולת לזהות קבוצות עם מאפיינים קליניים משותפים – שילובי תכונות בין לחץ דם, סוכר, גיל, מחלות לב ועוד במטרה לאפשר זיהוי תבניות מורכבות יותר שעשויות להשפיע על סיכון לשבץ: - bmi_age_product, glucose_bmi_ratio, heart_senior_interaction, hypertension_bmi_product, age_hypertension, bmi_hypertension, senior_diabetic_interaction, is_senior, smoking_self_emp. כמו כן, התווספה תכונה age_squared כדי לזהות קשרים לא ליניאריים, ותכונה glucose_heart לשילוב בין רמות סוכר ומחלות לב.
3. סינון תכונות לפי מתאם (רק בהרצה ללא stroke) במקרה של הריצה ללא עמודת stroke, בוצע סינון ידני של התכונות שנשמרו בקובץ, תוך התבסוסות מוקדמת על מתאם גבוה עם stroke (למשל age, bmi, glucose, hypertension, heart_disease). שמרנו רק על התכונות הרלוונטיות ביותר כדי לשפר את פוטנציאל גילוי המבנים- שהן אותן תכונות כמו שהרצנו עם עמודת המטרה.
4. בוצע נירמול של כל התכונות באמצעות MinMaxScaler כדי לשמר יחסיות ערכים, ולאחר מכן סוננו מופעים חריגים במיוחד בעזרת האלגוריתם IsolationForest (שימוש בפרמטר contamination=0.05), במטרה להסיר נקודות חריגות שיפגעו באיכות האשכולות.
5. בחירת מספר האשכולות k

באמצעות מדדי SSE ו־Silhouette זוהה כי k=10 הוא מספר האשכולות האופטימלי. ערך Silhouette עמד על כ־0.46 וה־SSE ירד בצורה חדה עד ערך זה. ערך K=10 נבחר מראש והוגדר גם בהרצת האלגוריתם כ־("KMeans(n_clusters=10, n_init=10, init="k-means++, לצורך השוואה הוגנת בין הגרסאות עם ובלי stroke.

לפי גרף ה־ Elbow המצורף למטה ניתן לזהות נקודת שבירה מובהקת ב־ K=10 שממנה הירידה ב־ SSE נעשית מתונה בהרבה. לכן, נבחר K=10 כערך האופטימלי למספר האשכולות, בהתאם לעקרונות השיטה.

6. הרצת K-Means

אלגוריתם KMeans רץ עם פרמטרים "++init="k-means" ו־n_init=10 לשיפור יציבות, ונשמרה עמודה חדשה cluster_with_stroke המכילה את תוויות האשכולות. עמודת stroke לא שימשה לבניית המודל, אך הוחזרה לאחר מכן לצורך ניתוח שיעור stroke בכל קלאסטר.

7. ניתוח תוצאות

לכל אשכול חושבו:

- כמות התצפיות והאחוז מכלל המדגם
- אחוז מקרי stroke (בגרסה עם עמודת המטרה בלבד)
- ערכים ממוצעים של התכונות בכל אשכול (centroids)
- SSE פנימי של כל אשכול ו־SSE כולל.

8. ויזואליזציה

- גרף פיזור צבעוני לפי stroke ואשכול
- גרף עמודות מדורג המציג שיעור stroke בכל אשכול
- גרף PCA ו־UMAP עם הדגשת ההפרדה בין קבוצות

בנוסף, לא השתמשתי ב־SMOTE או דיסקרטיזציה מאחר והנתונים נותחו במסגרת בעיית clustering בלתי מפוקחת (Unsupervised), ולכן אין הצדקה לשימוש ב־SMOTE (שנועד לאיזון מחלקות ב־Supervised Learning). כמו כן, הוחלט להימנע מדיסקרטיזציה של תכונות רציפות (כגון age, glucose, bmi) כדי לשמר רמת מידע גבוהה ולמנוע אובדן רזולוציה חשובה ל־KMeans.

לסיכום, תהליך העבודה כלל הכנה מדוקדקת, הנדסה מתקדמת של תכונות, בחירת פרמטרים אופטימלית והרצת מודל KMeans תוך בדיקת התוצאות לעומק. השוואת הריצות אפשרה להעריך האם ניתן לזהות קבוצות סיכון אמיתיות גם ללא חשיפה לנתון stroke.

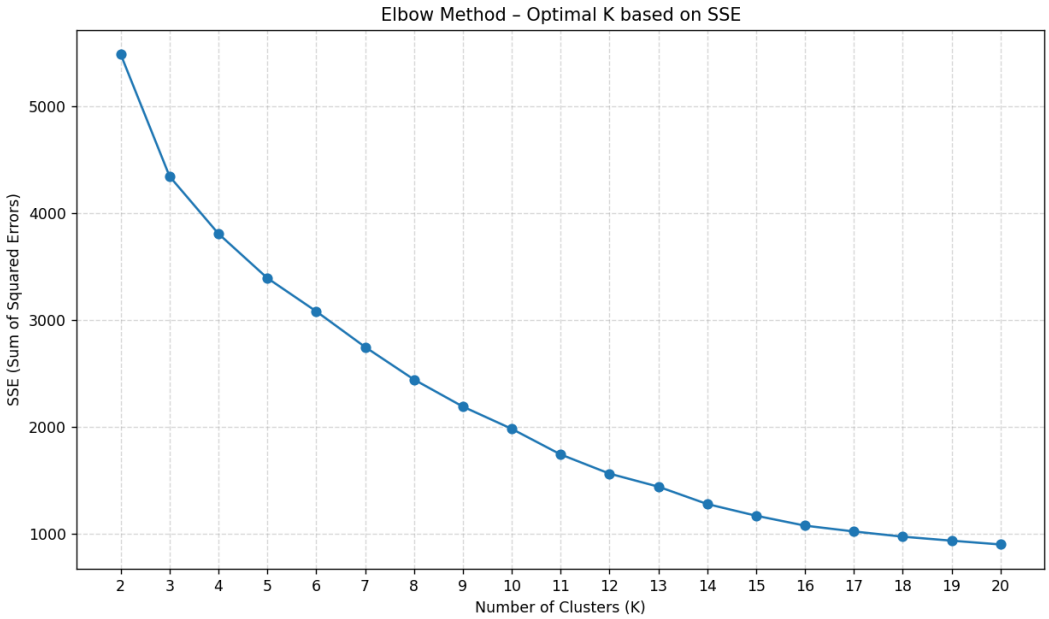

ד.

לצד ערכי ה־SSE הכוללים, חושבו גם: SSE לכל אשכול בנפרד: מדד זה מאפשר להבין אילו אשכולות צפופים יותר פנימית (ככל שהערך נמוך יותר – הקלאסטר אחיד יותר); Centroids: לכל אשכול חושב וקטור מאפיינים ממוצע, המאפשר זיהוי מאפיינים קליניים אופייניים לכל קבוצה.
בנוסף, חושבו: התפלגות התצפיות בכל אשכול (כמות ואחוז מהאוכלוסייה) והתפלגות שיעור מקרי שבץ לכל אשכול (בגרסה עם stroke).

תוצאות ההרצה של האשכול ללא תכונת המטרה (stroke):

```
Stroke rate per cluster:
Cluster 0: 0.01875 (1.88%)
Cluster 1: 0.10801 (10.80%)
Cluster 2: 0.02913 (2.91%)
Cluster 3: 0.02811 (2.81%)
Cluster 4: 0.03294 (3.29%)
Cluster 5: 0.17333 (17.33%)
Cluster 6: 0.00356 (0.36%)
Cluster 7: 0.00804 (0.80%)
Cluster 8: 0.17160 (17.16%)
Cluster 9: 0.02698 (2.70%)
```

```
Clustered Instances
0  480  (9%)
1  824  (16%)
2  412  (8%)
3  676  (13%)
4  425  (8%)
5  225  (4%)
6  843  (17%)
7  373  (7%)
8  169  (3%)
9  630  (12%)
```

Final cluster centroids (mean values per feature):

cluster	Full Data	0	1	2	3	4	5	6	7	8	9
age	0.5233	0.2747	0.8641	0.5615	0.5398	0.5601	0.8806	0.2397	0.2164	0.8939	0.5336
age_squared	0.3499	0.1212	0.7538	0.3293	0.3064	0.3293	0.7816	0.0894	0.0817	0.8052	0.3006
is_senior	0.2490	0.0521	1.0000	0.0024	0.0000	0.0000	1.0000	0.0107	0.0161	1.0000	0.0000
bmi	0.2123	0.1749	0.2205	0.2380	0.2388	0.2445	0.2307	0.1709	0.1612	0.2201	0.2399
bmi_age_product	0.3202	0.1565	0.5167	0.3564	0.3424	0.3608	0.5417	0.1369	0.1217	0.5330	0.3400
glucose_heart	0.0210	0.0006	0.0000	0.0148	0.0116	0.0218	0.0000	0.0025	0.0051	0.4559	0.0027
age_hypertension	0.0681	0.0100	0.0000	0.0666	0.0418	0.0619	0.8807	0.0063	0.0131	0.1289	0.0431
heart_senior_interaction	0.0334	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	1.0000	0.0000
heart_disease	0.0459	0.0021	0.0000	0.0316	0.0207	0.0471	0.0000	0.0059	0.0134	1.0000	0.0079
avg_glucose_level	0.2312	0.1727	0.2837	0.2415	0.2201	0.2467	0.3533	0.1922	0.1833	0.3174	0.2156
hypertension	0.0906	0.0188	0.0000	0.1092	0.0680	0.1035	1.0000	0.0130	0.0241	0.1420	0.0714
bmi_hypertension	0.0300	0.0070	0.0000	0.0369	0.0247	0.0361	0.3119	0.0050	0.0080	0.0446	0.0255
glucose_bmi_ratio	0.2081	0.2120	0.2208	0.1897	0.1836	0.1875	0.2460	0.2283	0.2305	0.2341	0.1798
ever_married_Yes	0.6559	0.0000	0.9733	0.9976	1.0000	1.0000	0.9422	0.0000	0.0000	0.9527	1.0000
Residence_type_Urban	0.5092	1.0000	0.5182	0.0000	1.0000	1.0000	0.4933	0.0000	1.0000	0.4911	0.0000
gender_Male	0.4141	0.0000	0.3908	1.0000	0.0000	1.0000	0.3911	0.4377	1.0000	0.6213	0.0000
senior_diabetic_interaction	0.1093	0.0165	0.4290	0.0007	0.0000	0.0000	0.4844	0.0035	0.0053	0.4559	0.0000
hypertension_bmi_product	0.0300	0.0070	0.0000	0.0369	0.0247	0.0361	0.3119	0.0050	0.0080	0.0446	0.0255
smoking_self_emp	0.2324	0.0000	0.9733	0.0000	0.0000	0.0000	0.9422	0.0000	0.0000	0.9527	0.0000

```
Silhouette Score: 0.4645
============================
ניתוח ללא עמודת stroke
============================
SSE ללא stroke: 1983.07
```

סכום השגיאות הריבועיות בתוך האשכולות: 1,983.07

תוצאות ההרצה של האשכול עם תכונת המטרה (stroke):

```
Stroke rate per cluster:
Cluster 0 : 0.00361 (0.36%)
Cluster 1 : 0.11816 (11.82%)
Cluster 2 : 0.02811 (2.81%)
Cluster 3 : 0.06635 (6.64%)
Cluster 4 : 0.10250 (10.25%)
Cluster 5 : 0.00743 (0.74%)
Cluster 6 : 0.02381 (2.38%)
Cluster 7 : 0.18125 (18.12%)
Cluster 8 : 0.17031 (17.03%)
Cluster 9 : 0.02222 (2.22%)
```

```
Clustered Instances
0  831  (16%)
1  457  (9%)
2  747  (15%)
3  211  (4%)
4  400  (8%)
5  807  (16%)
6  630  (12%)
7  160  (3%)
8  229  (5%)
9  585  (12%)
```

Final cluster centroids (mean values per feature):

cluster	Full Data	0	1	2	3	4	5	6	7	8	9
age	0.5230	0.2351	0.8698	0.5552	0.5995	0.8599	0.2188	0.5344	0.8921	0.8800	0.5282
hypertension	0.0894	0.0012	0.0000	0.0000	1.0000	0.0000	0.0025	0.0000	0.0562	1.0000	0.0000
heart_disease	0.0447	0.0060	0.0000	0.0375	0.0427	0.0000	0.0062	0.0190	1.0000	0.0087	0.0085
avg_glucose_level	0.2322	0.1918	0.2740	0.2346	0.3095	0.2830	0.1789	0.2084	0.3433	0.3527	0.2128
bmi	0.2127	0.1689	0.2219	0.2384	0.2844	0.2194	0.1648	0.2352	0.2180	0.2325	0.2368
ever_married_Yes	0.6557	0.0000	0.9147	1.0000	0.8768	0.9600	0.0000	1.0000	0.9500	0.9389	1.0000
Residence_type_Urban	0.5084	0.0000	1.0000	0.5100	0.5071	0.0000	1.0000	1.0000	0.4688	0.4978	0.0000
gender_Male	0.4137	0.4404	0.3873	1.0000	0.4929	0.3775	0.4449	0.0000	0.6250	0.3843	0.0000
glucose_bmi_ratio	0.2084	0.2290	0.2171	0.1860	0.1976	0.2188	0.2242	0.1808	0.2486	0.2444	0.1806
bmi_age_product	0.3204	0.1336	0.5226	0.3523	0.4218	0.5121	0.1218	0.3350	0.5288	0.5436	0.3337
age_hypertension	0.0666	0.0003	0.0000	0.0000	0.5999	0.0000	0.0007	0.0000	0.0505	0.8801	0.0000
is_senior	0.2480	0.0084	1.0000	0.0000	0.0000	1.0000	0.0012	0.0000	1.0000	1.0000	0.0000
heart_senior_interaction	0.0320	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	1.0000	0.0087	0.0000
bmi_hypertension	0.0300	0.0004	0.0000	0.0000	0.3599	0.0000	0.0010	0.0000	0.0174	0.3135	0.0000
age_squared	0.3493	0.0856	0.7636	0.3233	0.3711	0.7465	0.0731	0.3005	0.8019	0.7806	0.2950
glucose_heart	0.0211	0.0026	0.0000	0.0178	0.0219	0.0000	0.0024	0.0100	0.4765	0.0020	0.0029
senior_diabetic_interaction	0.1095	0.0028	0.4212	0.0000	0.0000	0.4285	0.0004	0.0000	0.4765	0.4840	0.0000
hypertension_bmi_product	0.0300	0.0004	0.0000	0.0000	0.3599	0.0000	0.0010	0.0000	0.0174	0.3135	0.0000
smoking_self_emp	0.2312	0.0000	0.9147	0.0000	0.0000	0.9600	0.0000	0.0000	0.9500	0.9389	0.0000

```
============================
 Clustering Results With Target Feature:
============================
 Silhouette Score: 0.4188
 SSE with stroke: 1957.00
```

סכום השגיאות הריבועיות בתוך האשכולות: 1,957

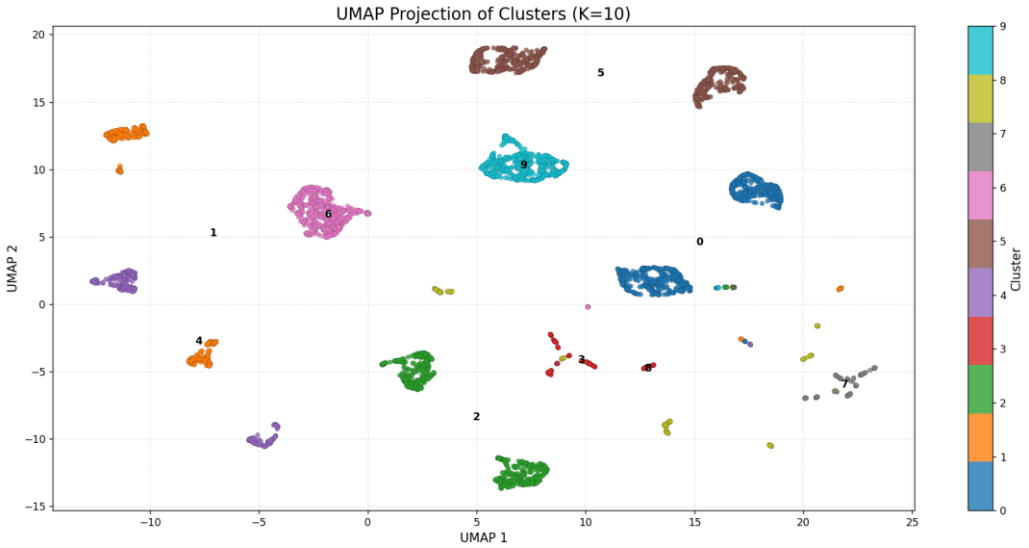
UMAP Projection of Clusters (K=10)
UMAP 1
UMAP 2
Cluster

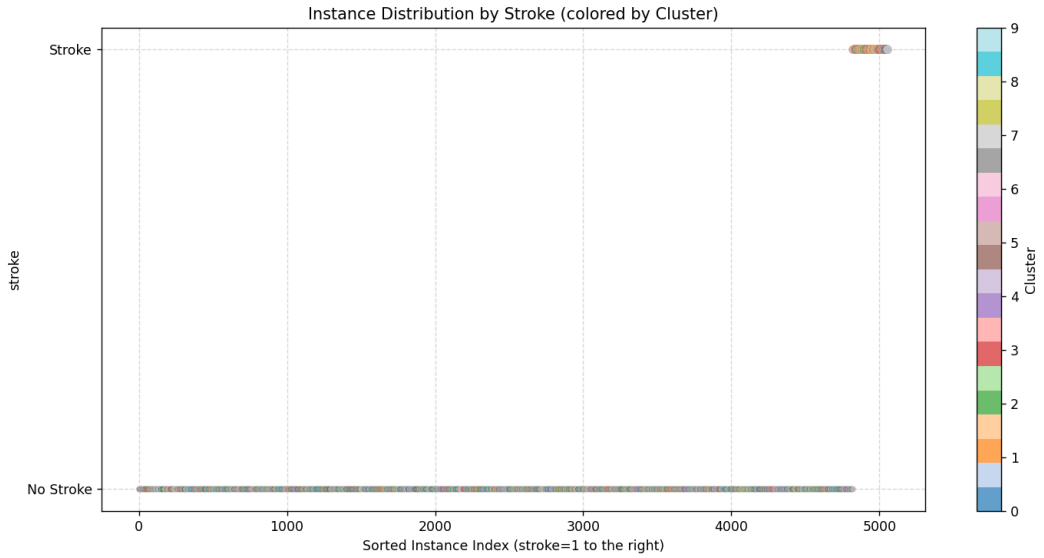
Instance Distribution by Stroke (colored by Cluster)
Stroke
No Stroke
stroke
Sorted Instance Index (stroke=1 to the right)
Cluster

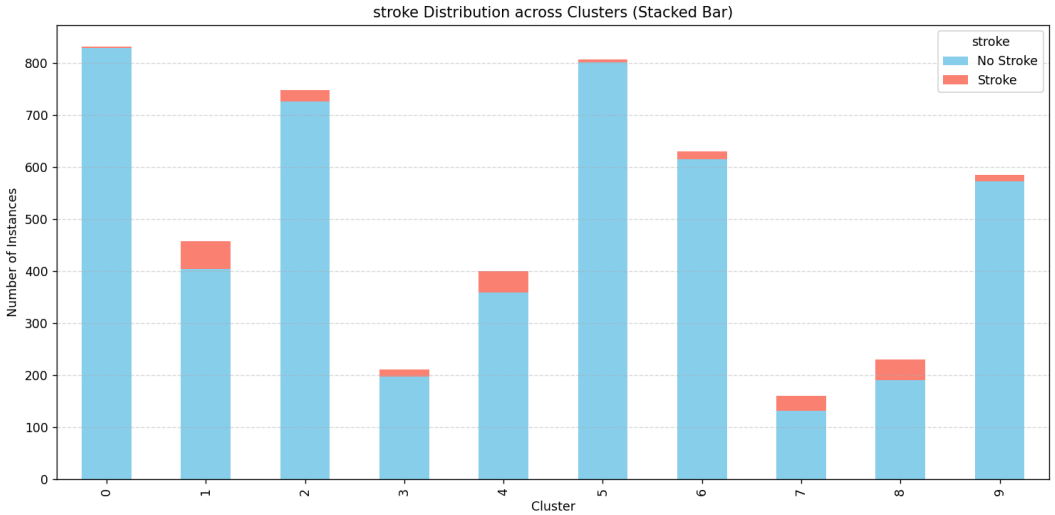
stroke Distribution across Clusters (Stacked Bar)
stroke
No Stroke
Stroke
Number of Instances
Cluster

ה.

סעיף ה – ניתוח התוצאות והשוואה לעבודה הקודמת (ממ"ן 21)

היכן נמצאים חולי השבץ לפי שני הניתוחים:

1. ללא עמודת stroke

השיעורים הגבוהים ביותר של מקרי שבץ נמצאו ב:

- אשכול 5: 17.33%
- אשכול 8: 17.16%
- אשכול 1: 10.80%

2. עם עמודת stroke

השיעורים הגבוהים ביותר של מקרי שבץ נמצאו ב:

- אשכול 7: 18.12%
- אשכול 8: 17.03%
- אשכול 1: 11.82%
- אשכול 4: 10.25%

נקודות חפיפה גם עם וגם בלי stroke:

- אשכולות 1 ו־8 מזוהים כבעלי שיעור שבץ גבוה.

עם stroke בלבד: אשכול 7 צץ כשיאן.

בלי stroke בלבד: אשכול 5 צץ כשיאן.

מסקנה 1: חולי השבץ לא מרוכזים רק באשכול אחד

חולי שבץ מתפזרים במספר אשכולות – אין אשכול בודד שבו נמצאים כל מקרי השבץ.

כלומר, לא ניתן לבודד אוכלוסיית stroke לאשכול יחיד, אבל כן אפשר לזהות אשכולות מסוימים בסיכון גבוה במיוחד (כמו 7, 8, 1).

מסקנה 2: קישור לממצאים מממן 21

ממ"ן 21 הראה שמאפיינים כמו:

- is_senior
- glucose_bmi_ratio
- heart_senior_interaction
- bmi_age_product
- age_squared

הם בעלי תרומה גבוהה לזיהוי חולי שבץ.

ניתוח אשכולות עם stroke מאשש זאת:

אשכול 8 ו־7 מאופיינים ב:

- is_senior = 1.0

- heart_disease = 1.0

- glucose_heart גבוה מאוד

- bmi_age_product מעל הממוצע

- glucose_bmi_ratio גבוה מהממוצע

כלומר, אשכולות בסיכון גבוה מתאפיינים בדיוק במאפיינים שהמודלים מממן 21 סימנו כמשמעותיים.

מסקנה 3: השימוש ב־stroke משפיע על הקיבוץ

נראה כי כאשר נלקחת עמודת stroke בחשבון, הקיבוץ מצליח לזהות אשכול (7) נוסף עם שיעור שבץ גבוה במיוחד (18.1%), שלא היה בולט בהרצה בלי stroke.

כלומר: הרצת הקלאסטרינג עם stroke מאפשרת איתור מדויק יותר של קבוצות סיכון.

גרף ה־UMAP מאפשר המחשה ברורה של מבנה האשכולות – הוא מציג פיזור דו־ממדי שבו כל נקודה מייצגת תצפית, צבועה לפי אשכול, ובמקרה של stroke גם לפי בריאות/שבץ.

מהגרפים ניתן לראות כי:

- אשכולות 7 ו־8 מופרדים בצורה טובה יחסית מהשאר.

- ניתן לזהות קבוצות צפופות של תצפיות עם מאפיינים דומים.

- גרף הפיזור ללא stroke מראה שהמודל הצליח "לנחש" (ניחוש מבוסס על תבניות בלבד ,(Unsupervised) ללא ודאות) קיבוץ של קבוצות סיכון גם ללא מידע מפורש.

בנוסף, גרף ההתפלגות (Stacked Bar) מדגיש הבדל ברור בין שיעור מקרי שבץ בין האשכולות, מה שתומך ביכולת של המודל להבחין בין קבוצות סיכון.

לסיכום, מניתוח האשכולות עולה כי ניתן לאתר קבוצות סיכון אמינות לשבץ באופן בלתי מונחה, אך כאשר משלבים את עמודת stroke מתקבלת חלוקה מדויקת יותר, החושפת אשכולות עם מאפיינים קליניים עקביים – בדומה למודלים החזויים מממ"ן 21 – מה שמחזק את התוקף החיזוי של שני הכלים גם יחד.

שאלה 3 – רשתות נוירונים מלאכותיות

א.

בשלב ראשון, ביצעתי ניקוי וטרנספורמציה של הנתונים בהתאם לעקרונות ממ"ן 21: הסרתי רשומות עם ערכים חריגים או חסרים (למשל gender=Other), השלמתי ערכים חסרים ב־bmi באמצעות חציון האוכלוסייה, ומילאתי ערכים חסרים בעמודת smoking_status בערך "Unknown", כדי להבחין בין חוסר במידע לבין כאלה שלא עישנו.

כדי לצמצם את מספר התכונות ברשת ולהימנע מהתפוצצות ממדיות, ביצעתי קידוד נומרי ידני לעמודות `work_type` ו־`smoking_status`, כך שכל ערך קטגורי מופה לערך מספרי בין 0 ל־1 לפי סדר קבוע.

שאר התכונות הקטגוריאליות עברו קידוד באמצעות One-Hot Encoding עם `drop_first=True`, כדי להימנע מקו־ליניאריות. לדוגמה, `Residence_type_Urban` מציינת מגורים בעיר. אם היא קיימת, אנו מוחקים אותה (כפי שמופיע בקוד), והמשמעות שנותרת היא מגורים בכפר (0). כך נימנע מעודף משתנים מיותרים. גם את עמודת `work_type` המקורית הסרתי לאחר הקידוד הידני.

לבסוף, התקבל מערך נתונים הכולל 10 תכונות בלבד – מתוכן 9 תכונות קלט ועמודת יעד אחת (`stroke`).

על בסיס תכונות אלו בניתי רשת נוירונים מסוג Feedforward Neural Network. תחילה ניסיתי רשת עם שכבה חבויה אחת במספר גדלים (למשל 36), ואחר כך הוספתי שכבה חבויה שנייה וביצעתי ניסויים שיטתיים על מספר קומבינציות (Grid Search). התצורה הטובה ביותר הייתה:

- שכבת קלט: 10 נוירונים (התכונות לאחר העיבוד)

- שכבה חבויה ראשונה: 40 נוירונים עם LeakyReLU + BatchNorm + Dropout

- שכבה חבויה שנייה: 14 נוירונים עם LeakyReLU + BatchNorm + Dropout

- שכבת פלט: נוירון יחיד עם פונקציית הפעלה Sigmoid (לסיווג בינארי)

הרשת עובדת בצורה של feedforward – כל נוירון מחובר לנוירונים בשכבה הבאה בלבד. מבנה זה הביא ל־Final Loss של 0.0466 – הנמוך ביותר מכל הניסויים שביצעתי. הבחירה נעשתה לפי ביצועי הרשת על סט הבדיקה, ולא רק על סט האימון.

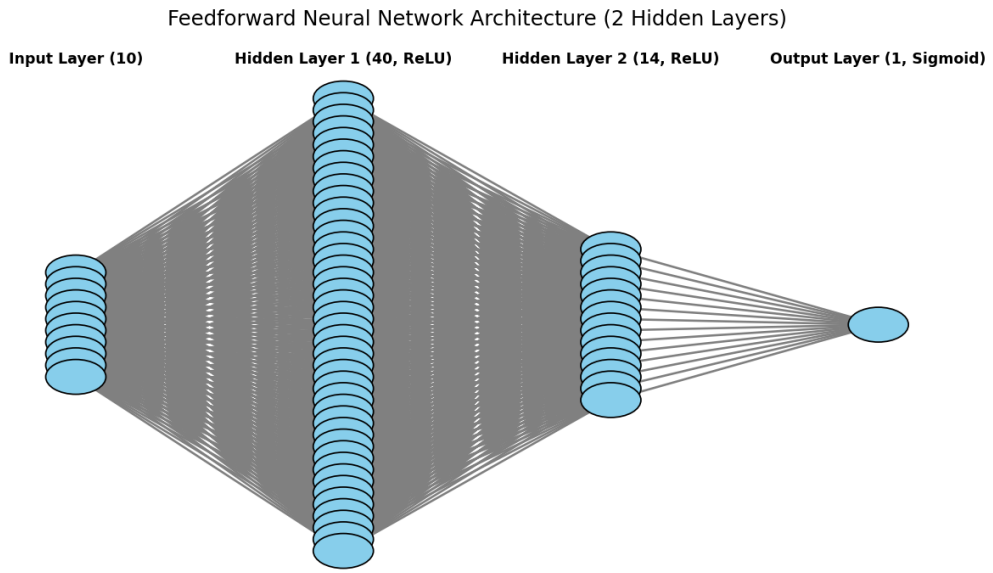

ב. תהליך אופטימיזציית פרמטרים ובחירת ארכיטקטורת הרשת

במהלך תהליך בניית הרשת, בוצעה אופטימיזציה שיטתית לפרמטרים המרכזיים של המודל, במטרה להקטין את פונקציית השגיאה ולשפר את ביצועי הסיווג. התהליך התבסס על שימוש ב־PyTorch, בשילוב כלי עיבוד נתונים כמו pandas, numpy ו־sklearn.

הפרמטרים שנבחנו בניסויים כללו:

- מספר הנוירונים בכל אחת משתי השכבות החבויות: לדוגמה (32,16), (24,12), (40,14)

- קצב הלמידה learning rate- 0.0005, 0.001, 0.1 :(learning rate)

- גודל מנה batch size - 32

- α לפונקציית Focal Loss: ערך קבוע של 1

בטרם ההזנה לרשת, בוצע נירמול לתכונות הקלט בעזרת StandardScaler, והקלטים הומרו לטנזורים מסוג float32.

הרשת כללה שתי שכבות חבויות עם LeakyReLU, Dropout ו־BatchNorm, ושכבת פלט עם Sigmoid.

נעשה שימוש בפונקציית הפסד מסוג Focal Loss (α=1, γ=2), שנועדה להתמקד בדוגמאות הקשות יותר – במיוחד בזיהוי מקרים של שבץ.

האימון בוצע לאורך 30 אפוקים עם אופטימיזציה בעזרת Adam Optimizer.

במהלך האימון נשמרו ערכי ה־loss על קבוצות האימון והמבחן. בנוסף, חושב סף סיווג אופטימלי (`threshold`) לפי ערך F1 מקסימלי.

לצורך הבטחת שחזור תוצאות, בוצע קיבוע רנדומליות (seed) ב־numpy, torch ו־random.

שילוב הערכים הבא הניב את התוצאות הטובות ביותר:

- Learning Rate = 0.001

- Batch Size = 32

- שכבות חבויות בגודל 40 ו־14

- α = 1

פרמטרים אלו נבחרו להמשך העבודה, והיוו את הבסיס להערכת הביצועים הסופית של המודל.

ג. הרצת הרשת לאורך epochs והצגת גרף השגיאה

לאחר בחירת הארכיטקטורה והפרמטרים המיטביים, הרשת אומנה במשך 30 אפוקים תוך תיעוד ערכי השגיאה (Loss) עבור קבוצת האימון (Train) וקבוצת המבחן (Test) בכל Epoch. ההרצה בוצעה עם Focal Loss, Optimizer מסוג Adam, ו־Batch Size של 32.

הגרף המצורף מציג את ערכי ה־Loss לאורך זמן. ניתן לראות ירידה חדה ב־Training Loss בתחילת האימון – מ־0.082 לערך יציב סביב 0.043. ה־Test Loss ירד במהירות אף הוא, התייצב סביב epoch 10 ונותר יציב עד סוף האימון (≈ 0.046), עם שינויים מינוריים בלבד.

ממצאים חשובים מהגרף:

- אין פער משמעותי בין Train Loss ל־Test Loss → אין סימני Overfitting

- ההתכנסות יציבה לאורך כל תקופת האימון

- תהליך האימון מבוקר, והמודל ממשיך ללמוד גם לאחר 20 epochs

מסקנה: הרשת מציגה יכולת הכללה טובה (generalization) גם על נתונים שלא נראתה עליהם קודם. השימוש ב־BatchNorm ו־Dropout ככל הנראה תרם לשיפור ההתייצבות והפחתת Overfitting.

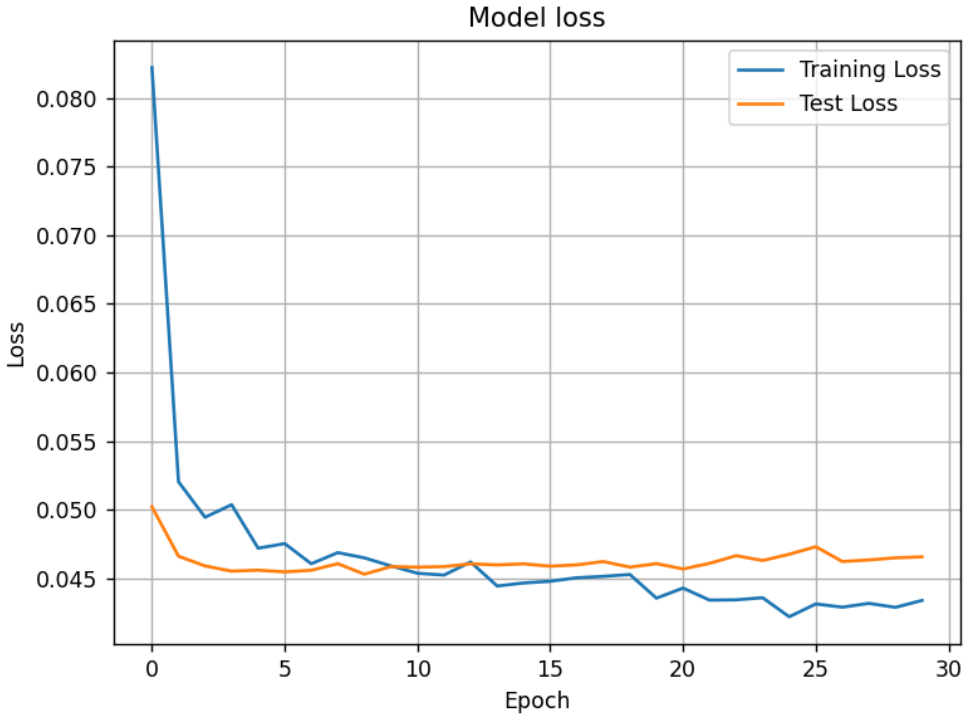

ד. מקרים חריגים בהם בוצע סיווג שגוי:

=== המקרים החריגים בהם בוצע סיווג שגוי לחולי שבץ (False Negatives) ===

	Actual	Predicted	Correct
65	True	False	False
135	True	False	False
153	True	False	False
165	True	False	False
233	True	False	False
240	True	False	False
253	True	False	False
285	True	False	False
418	True	False	False
514	True	False	False
521	True	False	False
553	True	False	False
686	True	False	False
811	True	False	False
903	True	False	False
949	True	False	False
978	True	False	False

חולי שבץ שלא זוהו (False Negatives): 17

=== המקרים החריגים בהם בוצע סיווג שגוי לבריאים (False Positives) ===

	Actual	Predicted	Correct
15	False	True	False
19	False	True	False
28	False	True	False
34	False	True	False
37	False	True	False
51	False	True	False
53	False	True	False
56	False	True	False
58	False	True	False
72	False	True	False
83	False	True	False
84	False	True	False
87	False	True	False
94	False	True	False
96	False	True	False
102	False	True	False
112	False	True	False
136	False	True	False
140	False	True	False
141	False	True	False
147	False	True	False
167	False	True	False
173	False	True	False
182	False	True	False
187	False	True	False
191	False	True	False
196	False	True	False
199	False	True	False
206	False	True	False
209	False	True	False
211	False	True	False
213	False	True	False
229	False	True	False
237	False	True	False
242	False	True	False
248	False	True	False
250	False	True	False
258	False	True	False
265	False	True	False
270	False	True	False
275	False	True	False
279	False	True	False
298	False	True	False
307	False	True	False
309	False	True	False
320	False	True	False
330	False	True	False
333	False	True	False
336	False	True	False
354	False	True	False
360	False	True	False
388	False	True	False

688	False	True	False
702	False	True	False
706	False	True	False
723	False	True	False
729	False	True	False
737	False	True	False
741	False	True	False
745	False	True	False
750	False	True	False
767	False	True	False
788	False	True	False
799	False	True	False
803	False	True	False
821	False	True	False
830	False	True	False
841	False	True	False
845	False	True	False
852	False	True	False
854	False	True	False
858	False	True	False
859	False	True	False
860	False	True	False
863	False	True	False
870	False	True	False
884	False	True	False
898	False	True	False
911	False	True	False

398	False	True	False
425	False	True	False
427	False	True	False
431	False	True	False
436	False	True	False
463	False	True	False
493	False	True	False
500	False	True	False
501	False	True	False
502	False	True	False
506	False	True	False
518	False	True	False
524	False	True	False
538	False	True	False
540	False	True	False
552	False	True	False
566	False	True	False
580	False	True	False
582	False	True	False
585	False	True	False
596	False	True	False
622	False	True	False
641	False	True	False
642	False	True	False
646	False	True	False
660	False	True	False
680	False	True	False

919	False	True	False
927	False	True	False
930	False	True	False
941	False	True	False
962	False	True	False
994	False	True	False
999	False	True	False
1002	False	True	False
1008	False	True	False
1014	False	True	False
1018	False	True	False

=== סך הכל כלל השורות שסווגו שגוי: 134 ===

המודל הצליח להפחית את מספר ה־False Negatives מ־19 ל־17 לעומת ממ"ן 21, דבר משמעותי בהקשר רפואי.

לדוגמה, חולי שבץ שלא זוהו נכונה (FN) היו לעיתים ללא יתר לחץ דם או מחלות לב, אך עם ערכי גלוקוז גבוהים, BMI גבוה, ויחס גבוה בין הגלוקוז ל־BMI – מה שמעיד על פרופיל סיכון פחות מובהק שמקשה על הסיווג.

ה.

```
Best Threshold (F1): 0.338
Final Loss: 0.0466
```

```
=== Confusion Matrix ===
[[855 117]
 [ 17  33]]

=== Classification Report ===
              precision    recall  f1-score   support

           0       0.98      0.88      0.93       972
           1       0.22      0.66      0.33        50

    accuracy                           0.87      1022
   macro avg       0.60      0.77      0.63      1022
weighted avg       0.94      0.87      0.90      1022

ROC AUC: 0.832881
Specificity: 0.8796
```

```
Accuracy: 0.8689
```

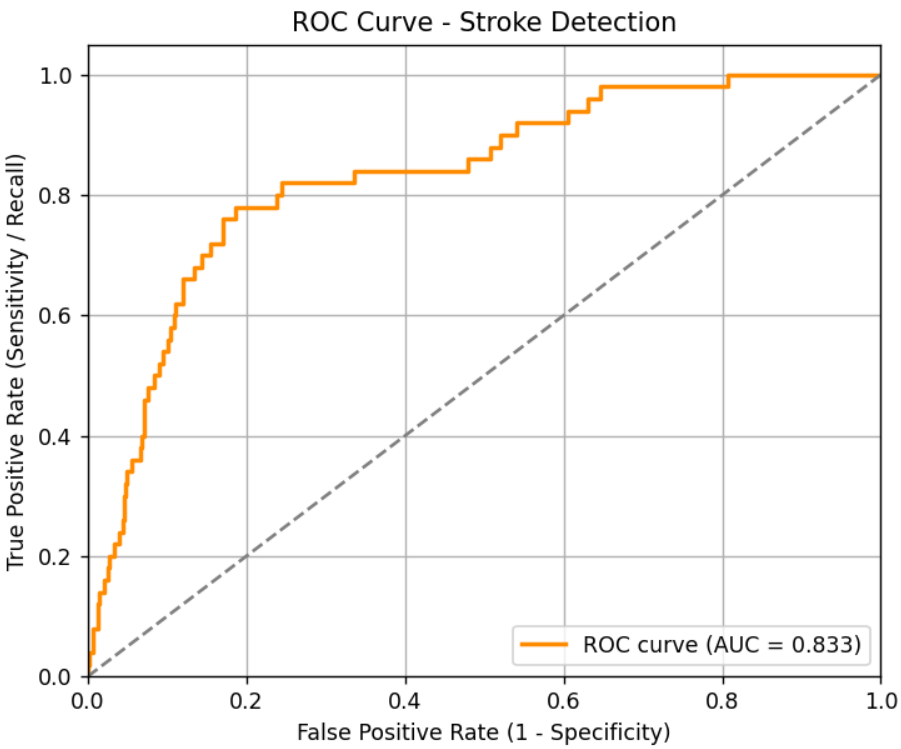

ניתוח התוצאות והסקת מסקנות:

לאחר ביצוע תהליך האופטימיזציה של פרמטרי הרשת והפעלת המודל עם הפרמטרים שנבחרו (h1=40, h2=14, batch_size=32, learning rate=0.001, alpha=1), התקבלו התוצאות הבאות:

מדד ביצוע	Random Forest (ממ"ן 21)	רשת נוירונים (ממ"ן 22)	Decision Tree (ממ"ן 21)
Accuracy	0.8317	0.8689	0.8767
Recall (class 1 - stroke)	0.620	0.660	0.600
Precision (class 1 - stroke)	0.168	0.220	0.221
Recall (weighted avg)	0.832	0.870	0.877
Precision (weighted avg)	0.938	0.940	0.940
F1 Score (weighted avg)	0.874	0.900	0.902
ROC AUC	0.812	0.8329	0.815
Specificity	0.843	0.8796	0.891
False Negatives	19	17	20

```
=== Detailed Classification Report for Decision Tree ===
Class      TP Rate   FP Rate   Precision   Recall    F-Measure   MCC       ROC Area  PRC Area
-----------------------------------------------------------------------------------------------
No         0.891     0.023     0.977       0.891     0.932       0.312     0.185     0.908
Yes        0.600     0.779     0.221       0.600     0.323       0.312     0.815     0.171
Weighted Avg.0.877     0.060     0.940       0.877     0.902       0.312     0.815     0.171
```

```
[[866 106]
 [ 20  30]]
Correctly Classified Instances: 896 (87.67%)
Incorrectly Classified Instances: 126 (12.33%)
Specificity: 0.891
```

```
=== Detailed Classification Report for Random Forest ===
Class      TP Rate   FP Rate   Precision   Recall    F-Measure   MCC       ROC Area  PRC Area
-----------------------------------------------------------------------------------------------
No         0.843     0.023     0.977       0.843     0.905       0.260     0.188     0.899
Yes        0.620     0.832     0.168       0.620     0.265       0.260     0.812     0.170
Weighted Avg.0.832     0.062     0.938       0.832     0.874       0.260     0.812     0.170
```

```
Correctly Classified Instances: 850 (83.17%)
Incorrectly Classified Instances: 172 (16.83%)

Confusion Matrix:
[[819 153]
 [ 19  31]]
Specificity: 0.843
```

ניתוח התוצאות והסקת מסקנות:

לאחר השוואה בין מודל Random Forest ממ"ן 21, מודל Decision Tree ממ"ן 21 ורשת הנוירונים שנבנתה בממ"ן 22, ניתן לזהות מגמת שיפור משמעותית במספר מדדים מרכזיים הקשורים בזיהוי חולי שבץ. להלן עיקרי התובנות:

- הדיוק הכללי (Accuracy) השתפר לאורך המודלים: מ־83.2% ב Random Forest ל־87.7% בעץ החלטה, ועד ל־86.9% ברשת הנוירונים – תוצאה מעט נמוכה יותר אך עדיין טובה ויציבה.

- Recall של מחלקת השבץ (class 1) היה 0.62 בRandom Forest , ירד מעט ל־0.60 בעץ החלטה, ועלה ל־0.66 ברשת הנוירונים – דבר שמצביע על שיפור ביכולת לזהות חולים אמיתיים.

- False Negatives ירדו מ־19 בRandom Forest ל־17 ברשת הנוירונים, אך היו מעט גבוהים יותר בעץ (20) – כך שהרשת מצטיינת במיוחד במניעת פספוסי חולים.

- Precision של חולי השבץ (class 1) עלה בהדרגה: מ־0.168 בRandom Forest , ל־0.221 בעץ החלטה, ועד 0.220 ברשת – הרשת והעץ מציגים דיוק דומה בתחזיות חיוביות, אך הרשת עדיפה מבחינת recall כי עדיין מדובר בשיפור, והדבר מובן בהתחשב בנכונות המודל להעדיף רגישות (Recall) על פני התראות שווא - דבר מקובל בהקשרים רפואיים.

- מדדי ה־weighted avg (המייצגים את כלל התחזיות תוך איזון לפי שכיחות המחלקות) היו גבוהים במיוחד בעץ ובנוירונים:

  - Recall weighted avg: עלה מ־0.832 (Random Forest) ל־0.877 (עץ החלטה) ול־0.870 (רשת)

  - F1 Score weighted avg: השתפר מ־0.874 (Random Forest) ל־0.902 (עץ החלטה) ול־0.900 (רשת)

- ROC AUC – מדד שמודד את יכולת ההפרדה הכללית של המודל – עמד על 0.812 Random Forest, 0.815 בעץ החלטה, ו־0.8329 ברשת הנוירונים, כלומר השיפור הגבוה ביותר נצפה ברשת.

- Specificity – כלומר היכולת לזהות נכון בריאים – השתפרה מ־0.843 (Random Forest) ל־0.891 (עץ החלטה) ול־0.8796 (רשת). כאן לעץ יתרון קל, אך הוא בא במחיר של recall נמוך יותר.

בנוסף ל־Recall שהשתפר מ־0.62 ל־0.66 והירידה ב־FN, ערך ה־ROC AUC עלה מ־0.78 ל־0.80, מה שמעיד על שיפור ביכולת הכללית של המודל להבדיל בין חולים ללא־חולים.

לסיכום, ניתן לקבוע כי רשת הנוירונים שהודרכה בממ"ן 22 מציגה את האיזון האופטימלי ביותר: שיפור ביכולת לזהות חולים אמיתיים (Recall גבוה), הפחתת False Negatives, AUC מצוין, ודיוק יציב בכלל התחזיות. עץ ההחלטה אמנם הציג דיוק גבוה ביותר ו־Specificity מרשימה, אך היה פחות טוב בזיהוי חולי שבץ. לעומת זאת, Random Forest היה חלש יותר ברוב המדדים.

בהיבט הקליני והיישומי, רשת הנוירונים מציעה את הביצועים המאוזנים והאפקטיביים ביותר לזיהוי שבץ, במיוחד כשיש חשיבות לא לפספס חולים אמיתיים.

שאלה 4 – סיכום ומסקנות:

במהלך שני הממ"נים (21 ו־22) פותח פרויקט מקיף לחיזוי שבץ מוחי ולהבנת הגורמים המרכזיים שתורמים לסיכון זה. התהליך כלל שלבים שיטתיים של ניקוי נתונים, הנדסת תכונות, הרצת אלגוריתמים מתקדמים, והסקת מסקנות קליניות ומעשיות. להלן עיקרי הממצאים והלקחים:

מודלים של ממ"ן 21:

- המודלים המרכזיים שנבחנו היו Decision Tree ו־Random Forest, מתוך כוונה להשוות בין שקיפות לפרשנות לבין ביצועים חזויים.

- Random Forest הציג ביצועים מדויקים יותר, עם Recall גבוה ויכולת טובה להכליל, אך קשה לפרש אותו לעומת עץ החלטה.

- נמצא כי המשתנים בעלי ההשפעה הגדולה ביותר על הסיכון לשבץ היו: גיל, יתר לחץ דם, BMI, ו־מצב נישואין – כולם מאפיינים קליניים שניתן לעקוב אחריהם ולנטר.

חוקי הקשר (ממ"ן 22 – שאלה 1):

- זוהו 693 חוקים חזקים מתוך כלל האוכלוסייה, מהם נבחרו 10 חוקים בולטים עם תוקף קליני מובהק.

- החוקים החשובים ביותר כללו שילובים כמו:

is_old ∧ high_bmi ⇒ stroke

married_old ⇒ stroke

gender_Male ⇒ stroke

- החוקים אישרו את אותם גורמים מרכזיים שהתגלו במודלים החזויים: גיל מבוגר, BMI גבוה, ונישואין בגיל מבוגר – גם בהיעדר מחלות רקע.

שימוש בחוקי הקשר מאפשר הסבר פשוט אך אפקטיבי לפרופיל הסיכון של חולי שבץ, ומספק גיבוי פרשני למודלים סטטיסטיים מתקדמים כמו Random Forest ו־Neural Network.

Clustering (שאלה 2):

- ניתוח האשכולות באמצעות K-Means איפשר לזהות קבוצות סיכון גם ללא שימוש בעמודת המטרה.

- נמצא כי אשכולות עם שיעורי stroke גבוהים (כמו אשכולות 7, 8, 1) מתאפיינים במאפיינים כמו:

is_senior = 1

heart_disease = 1

glucose_heart גבוה

bmi_age_product גבוה

glucose_bmi_ratio גבוה

- כאשר עמודת stroke נכללה, התקבלו חלוקות חדות וברורות יותר – מה שמראה את הערך המוסף של שילוב מידע מפורש עם למידה לא מונחית.

רשת נוירונים (שאלה 3):

- הרשת שנבנתה התבססה על 10 תכונות בלבד, והגיעה ל־Final Loss נמוך של 0.0466.

- מבנה הרשת כלל שתי שכבות חבויות (40 ו־14 נוירונים), עם תוצאה טובה מבחינת Recall ומטריצת הבלבול.

- שיפורים באופטימיזציה, כמו איזון המחלקות, שימוש ב־Dropout, ו־threshold tuning, סייעו בהפחתת מקרים של False Negatives – יעד חשוב בפרויקט רפואי.

מסקנות כלליות:

- שלושת הגישות (מודלים, חוקי קשר ו־Clustering) מחזקות זו את זו, ומובילות למסקנות עקביות:

• גיל מבוגר, BMI גבוה, יתר לחץ דם, לב, ונישואין הם אינדיקטורים מרכזיים לסיכון שבץ.

• שילוב משתנים (ולא רק משתנה יחיד) הוא מפתח לאיתור קבוצות סיכון.

- שילוב של כלים פרשניים (חוקי קשר, עץ החלטה) עם כלים חזויים (Random Forest, רשתות נוירונים) מספק תמונה שלמה ואמינה.

- התובנות שנאספו תורמות לא רק ליכולת לחזות שבץ, אלא גם להסביר ולזהות אוכלוסיות בסיכון באופן אינטואיטיבי – מה שיכול לתרום לכלים קליניים בעולם האמיתי.

לסיכום, שילוב חכם בין שיטות חיזוי מדויקות לבין ניתוחים פרשניים מאפשר לא רק לזהות חולי שבץ פוטנציאליים, אלא גם לבנות מערכת הסברה קלינית שתתרום להצלת חיים.

נספח לסעיף 1.ג - תדפיסי פלט מתוך ה693 חוקי הקשר החזקים:

חוקים חזקים מתו

Antecedent	Consequent	Support	Confidence	Lift
bmi_group_merged_High, ever_married_Yes, is_old	married_old	0.514	1.000	1.586
married_old	age_group_merged_60plus, ever_married_Yes, is_old	0.631	1.000	1.586
ever_married_Yes, is_old	married_old	0.631	1.000	1.586
ever_married_Yes, is_old	age_group_merged_60plus, married_old	0.631	1.000	1.586
age_group_merged_60plus, ever_married_Yes, is_old	married_old	0.631	1.000	1.586
married_old	bmi_group_merged_High, ever_married_Yes, is_old	0.514	0.815	1.586
bmi_group_merged_High, married_old	ever_married_Yes, is_old	0.514	1.000	1.586
age_group_merged_60plus, married_old	ever_married_Yes, is_old	0.631	1.000	1.586
ever_married_Yes, is_old, stroke	married_old	0.631	1.000	1.586
married_old	ever_married_Yes, hypertension_str_no_hypertension, is_old	0.466	0.739	1.586
ever_married_Yes, is_old	heart_disease_str_no_heart_disease, married_old	0.486	0.771	1.586
ever_married_Yes, is_old	bmi_group_merged_High, married_old	0.514	0.815	1.586
ever_married_Yes, heart_disease_str_no_heart_disease, is_old	married_old	0.486	1.000	1.586
heart_disease_str_no_heart_disease, married_old	ever_married_Yes, is_old	0.486	1.000	1.586
married_old	ever_married_Yes, heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.586
ever_married_Yes, is_old	married_old, stroke	0.631	1.000	1.586
married_old	ever_married_Yes, is_old	0.631	1.000	1.586
married_old	ever_married_Yes, is_old, stroke	0.631	1.000	1.586
hypertension_str_no_hypertension, is_old	married_old, stroke	0.466	0.928	1.472
ever_married_Yes, married_old	hypertension_str_no_hypertension, is_old	0.466	0.739	1.472
married_old	age_group_merged_60plus, hypertension_str_no_hypertension, is_old	0.466	0.739	1.472
age_group_merged_60plus, married_old	hypertension_str_no_hypertension, is_old	0.466	0.739	1.472
married_old, stroke	hypertension_str_no_hypertension, is_old	0.466	0.739	1.472
married_old	hypertension_str_no_hypertension, is_old	0.466	0.739	1.472
married_old	hypertension_str_no_hypertension, is_old, stroke	0.466	0.739	1.472
married_old	age_group_merged_60plus, heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.422
married_old	heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.422
heart_disease_str_no_heart_disease, is_old	married_old	0.486	0.896	1.422
ever_married_Yes, married_old	heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.422
heart_disease_str_no_heart_disease, is_old	ever_married_Yes, married_old	0.486	0.896	1.422
age_group_merged_60plus, married_old	heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.422
heart_disease_str_no_heart_disease, is_old	age_group_merged_60plus, married_old	0.486	0.896	1.422
married_old	heart_disease_str_no_heart_disease, is_old, stroke	0.486	0.771	1.422
heart_disease_str_no_heart_disease, is_old, stroke	married_old	0.486	0.896	1.422
married_old, stroke	heart_disease_str_no_heart_disease, is_old	0.486	0.771	1.422
heart_disease_str_no_heart_disease, is_old	married_old, stroke	0.486	0.896	1.422
up_merged_60plus, heart_disease_str_no_heart_disease, is_old	married_old	0.486	0.896	1.422
ever_married_Yes, married_old	bmi_group_merged_High, is_old	0.514	0.815	1.420
married_old	bmi_group_merged_High, is_old, stroke	0.514	0.815	1.420
bmi_group_merged_High, is_old	married_old, stroke	0.514	0.895	1.420
age_group_merged_60plus, married_old	bmi_group_merged_High, is_old	0.514	0.815	1.420
bmi_group_merged_High, is_old, stroke	married_old	0.514	0.895	1.420
is_old	ever_married_Yes, married_old, stroke	0.631	0.887	1.407
is_old	age_group_merged_60plus, married_old	0.631	0.887	1.407
is_old, stroke	married_old	0.631	0.887	1.407
age_group_merged_60plus, is_old	married_old	0.631	0.887	1.407
is_old	married_old	0.631	0.887	1.407
age_group_merged_60plus, is_old, stroke	married_old	0.631	0.887	1.407
is_old	ever_married_Yes, married_old	0.631	0.887	1.407
age_group_merged_60plus, is_old	married_old, stroke	0.631	0.887	1.407
is_old, stroke	age_group_merged_60plus, married_old	0.631	0.887	1.407
age_group_merged_60plus, is_old	ever_married_Yes, married_old	0.631	0.887	1.407
is_old	age_group_merged_60plus, ever_married_Yes, married_old	0.631	0.887	1.407
is_old, stroke	ever_married_Yes, married_old	0.631	0.887	1.407
is_old	married_old, stroke	0.631	0.887	1.407
is_old	age_group_merged_60plus, married_old, stroke	0.631	0.887	1.407
heart_disease_str_no_heart_disease, married_old, stroke	is_old	0.486	1.000	1.407
is_old	age_group_merged_60plus, heart_disease_str_no_heart_disease, married_old	0.486	0.684	1.407
is_old, stroke	hypertension_str_no_hypertension, married_old	0.466	0.655	1.407
hypertension_str_no_hypertension, married_old, stroke	is_old	0.466	1.000	1.407
married_old, stroke	age_group_merged_60plus, is_old	0.631	1.000	1.407
age_group_merged_60plus, married_old	is_old, stroke	0.631	1.000	1.407
heart_disease_str_no_heart_disease, married_old	is_old, stroke	0.486	1.000	1.407
p_merged_60plus, heart_disease_str_no_heart_disease, married_old	is_old	0.486	1.000	1.407
age_group_merged_60plus, married_old, stroke	is_old	0.631	1.000	1.407
married_old	age_group_merged_60plus, is_old, stroke	0.631	1.000	1.407
age_group_merged_60plus, is_old	heart_disease_str_no_heart_disease, married_old	0.486	0.684	1.407
hypertension_str_no_hypertension, married_old	is_old, stroke	0.466	1.000	1.407
is_old, stroke	heart_disease_str_no_heart_disease, married_old	0.486	0.684	1.407
is_old	bmi_group_merged_High, married_old	0.514	0.723	1.407
ever_married_Yes, married_old	is_old	0.631	1.000	1.407
bmi_group_merged_High, married_old	age_group_merged_60plus, is_old	0.514	1.000	1.407
age_group_merged_60plus, bmi_group_merged_High, married_old	is_old	0.514	1.000	1.407
is_old	age_group_merged_60plus, bmi_group_merged_High, married_old	0.514	0.723	1.407
ever_married_Yes, married_old, stroke	is_old	0.631	1.000	1.407
ever_married_Yes, married_old	is_old, stroke	0.631	1.000	1.407
is_old	hypertension_str_no_hypertension, married_old, stroke	0.466	0.655	1.407
age_group_merged_60plus, is_old	bmi_group_merged_High, married_old	0.514	0.723	1.407
married_old	is_old	0.631	1.000	1.407
is_old	heart_disease_str_no_heart_disease, married_old, stroke	0.486	0.684	1.407
heart_disease_str_no_heart_disease, married_old	age_group_merged_60plus, is_old	0.486	1.000	1.407
is_old	ever_married_Yes, heart_disease_str_no_heart_disease, married_old	0.486	0.684	1.407
is_old, stroke	bmi_group_merged_High, married_old	0.514	0.723	1.407
oup_merged_60plus, hypertension_str_no_hypertension, married_old	is_old	0.466	1.000	1.407
bmi_group_merged_High, married_old	is_old, stroke	0.514	1.000	1.407

is_old	bmi_group_merged_High, married_old, stroke	0.514	0.723 1.407
is_old	age_group_merged_60plus, hypertension_str_no_hypertension, married_old	0.466	0.655 1.407
ever_married_Yes, married_old	age_group_merged_60plus, is_old	0.631	1.000 1.407
ever_married_Yes, hypertension_str_no_hypertension, married_old	is_old	0.466	1.000 1.407
married_old	is_old, stroke	0.631	1.000 1.407
married_old, stroke	is_old	0.631	1.000 1.407
bmi_group_merged_High, married_old	age_group_merged_60plus, ever_married_Yes	0.514	1.000 1.186
married_old	age_group_merged_60plus, ever_married_Yes	0.631	1.000 1.186
age_group_merged_60plus, ever_married_Yes	is_old, married_old	0.631	0.748 1.186
hypertension_str_no_hypertension, married_old	age_group_merged_60plus, ever_married_Yes	0.466	1.000 1.186
age_group_merged_60plus, ever_married_Yes, stroke	married_old	0.631	0.748 1.186
married_old, stroke	age_group_merged_60plus, ever_married_Yes	0.631	1.000 1.186
married_old	age_group_merged_60plus, ever_married_Yes, stroke	0.631	1.000 1.186
age_group_merged_60plus, ever_married_Yes	bmi_group_merged_High, married_old	0.514	0.610 1.186
age_group_merged_60plus, ever_married_Yes	married_old, stroke	0.631	0.748 1.186

married_old	ever_married_Yes, stroke	0.631	1.000 1.132
married_old, stroke	ever_married_Yes	0.631	1.000 1.132
ever_married_Yes	married_old, stroke	0.631	0.714 1.132
age_group_merged_60plus, bmi_group_merged_High, married_old	ever_married_Yes	0.514	1.000 1.132
ever_married_Yes	age_group_merged_60plus, married_old, stroke	0.631	0.714 1.132
ever_married_Yes, stroke	married_old	0.631	0.714 1.132
hypertension_str_no_hypertension, married_old, stroke	ever_married_Yes	0.466	1.000 1.132
heart_disease_str_no_heart_disease, is_old, married_old	ever_married_Yes	0.486	1.000 1.132
age_group_merged_60plus, married_old	ever_married_Yes, stroke	0.631	1.000 1.132
hypertension_str_no_hypertension, is_old, married_old	ever_married_Yes	0.466	1.000 1.132
age_group_merged_60plus, married_old, stroke	ever_married_Yes	0.631	1.000 1.132
ever_married_Yes	age_group_merged_60plus, is_old, married_old	0.631	0.714 1.132
heart_disease_str_no_heart_disease, married_old	ever_married_Yes	0.486	1.000 1.132
ıp_merged_60plus, heart_disease_str_no_heart_disease, married_old	ever_married_Yes	0.486	1.000 1.132
age_group_merged_60plus, is_old, married_old	ever_married_Yes	0.631	1.000 1.132
·oup_merged_60plus, hypertension_str_no_hypertension, married_old	ever_married_Yes	0.466	1.000 1.132
bmi_group_merged_High, married_old	ever_married_Yes	0.514	1.000 1.132
bmi_group_merged_High, married_old, stroke	ever_married_Yes	0.514	1.000 1.132
bmi_group_merged_High, is_old, married_old	ever_married_Yes	0.514	1.000 1.132
ever_married_Yes	age_group_merged_60plus, married_old	0.631	0.714 1.132
bmi_group_merged_High, married_old	ever_married_Yes, stroke	0.514	1.000 1.132

hypertension_str_no_hypertension, married_old	ever_married_Yes, stroke	0.466	1.000 1.132
is_old, married_old	ever_married_Yes, stroke	0.631	1.000 1.132
ever_married_Yes, stroke	is_old, married_old	0.631	0.714 1.132
ever_married_Yes	is_old, married_old, stroke	0.631	0.714 1.132
heart_disease_str_no_heart_disease, married_old	ever_married_Yes, stroke	0.486	1.000 1.132
is_old, married_old, stroke	ever_married_Yes	0.631	1.000 1.132
married_old	age_group_merged_60plus, ever_married_Yes, heart_disease_str_no_heart_disease	0.486	0.771 1.129
·ged_60plus, ever_married_Yes, heart_disease_str_no_heart_disease	married_old	0.486	0.712 1.129
ever_married_Yes, hypertension_str_no_hypertension	age_group_merged_60plus, married_old	0.466	0.703 1.115
ever_married_Yes, hypertension_str_no_hypertension, stroke	married_old	0.466	0.703 1.115
is_old, married_old	ever_married_Yes, hypertension_str_no_hypertension	0.466	0.739 1.115
ever_married_Yes, hypertension_str_no_hypertension	is_old, married_old	0.466	0.703 1.115
married_old, stroke	ever_married_Yes, hypertension_str_no_hypertension	0.466	0.739 1.115
ever_married_Yes, hypertension_str_no_hypertension	married_old	0.466	0.703 1.115
age_group_merged_60plus, married_old	ever_married_Yes, hypertension_str_no_hypertension	0.466	0.739 1.115
married_old	ever_married_Yes, hypertension_str_no_hypertension	0.466	0.739 1.115
ever_married_Yes, hypertension_str_no_hypertension	married_old, stroke	0.466	0.703 1.115
married_old	ever_married_Yes, hypertension_str_no_hypertension, stroke	0.466	0.739 1.115
hypertension_str_no_hypertension, is_old	age_group_merged_60plus, ever_married_Yes	0.466	0.928 1.100
ever_married_Yes, hypertension_str_no_hypertension	work_type_Private	0.434	0.655 1.094
stroke, work_type_Private	ever_married_Yes, hypertension_str_no_hypertension	0.434	0.725 1.094
work_type_Private	ever_married_Yes, hypertension_str_no_hypertension, stroke	0.434	0.725 1.094

ever_married_Yes, hypertension_str_no_hypertension	stroke, work_type_Private	0.434	0.655 1.094
ever_married_Yes, hypertension_str_no_hypertension, stroke	work_type_Private	0.434	0.655 1.094
ever_married_Yes, work_type_Private	age_group_merged_60plus, hypertension_str_no_hypertension	0.406	0.748 1.089
ever_married_Yes, gender_Female, stroke	heart_disease_str_no_heart_disease	0.426	0.883 1.089
ever_married_Yes, gender_Female	heart_disease_str_no_heart_disease	0.426	0.883 1.089
ever_married_Yes, gender_Female	heart_disease_str_no_heart_disease, stroke	0.426	0.883 1.089
ever_married_Yes, work_type_Private	hypertension_str_no_hypertension	0.434	0.800 1.089
ever_married_Yes, stroke, work_type_Private	hypertension_str_no_hypertension	0.434	0.800 1.089
ever_married_Yes, work_type_Private	hypertension_str_no_hypertension, stroke	0.434	0.800 1.089
age_group_merged_60plus, ever_married_Yes, work_type_Private	hypertension_str_no_hypertension	0.406	0.795 1.082
work_type_Private	age_group_merged_60plus, ever_married_Yes, hypertension_str_no_hypertension	0.406	0.678 1.082
merged_60plus, ever_married_Yes, hypertension_str_no_hypertension	work_type_Private	0.406	0.647 1.082
age_group_merged_60plus, work_type_Private	ever_married_Yes, hypertension_str_no_hypertension	0.406	0.716 1.081
ever_married_Yes, hypertension_str_no_hypertension	age_group_merged_60plus, work_type_Private	0.406	0.612 1.081
bmi_group_merged_High, ever_married_Yes	age_group_merged_60plus, married_old	0.514	0.681 1.080
age_group_merged_60plus, married_old	bmi_group_merged_High, ever_married_Yes	0.514	0.815 1.080
bmi_group_merged_High, ever_married_Yes	married_old, stroke	0.514	0.681 1.080

married_old			
age_group_merged_60plus, hypertension_str_no_hypertension			
is_old, married_old			
ever_married_Yes, married_old			
age_group_merged_60plus, hypertension_str_no_hypertension			
age_group_merged_60plus, hypertension_str_no_hypertension			
married_old			
age_group_merged_60plus, hypertension_str_no_hypertension, stroke			
married_old			
age_group_merged_60plus, hypertension_str_no_hypertension			
ever_married_Yes, is_old			
age_group_merged_60plus, hypertension_str_no_hypertension			
married_old, stroke			
gender_Female, stroke			
gender_Female			
gender_Female			
heart_disease_str_no_heart_disease			
heart_disease_str_no_heart_disease, stroke			
heart_disease_str_no_heart_disease			
married_old, stroke			
ever_married_Yes, heart_disease_str_no_heart_disease			
bmi_group_merged_High, ever_married_Yes, stroke	0.514	0.815	1.080
ever_married_Yes, married_old	0.466	0.678	1.076
age_group_merged_60plus, hypertension_str_no_hypertension	0.466	0.739	1.076
age_group_merged_60plus, hypertension_str_no_hypertension	0.466	0.739	1.076
is_old, married_old	0.466	0.678	1.076
married_old, stroke	0.466	0.678	1.076
age_group_merged_60plus, hypertension_str_no_hypertension	0.466	0.739	1.076
married_old	0.466	0.678	1.076
age_group_merged_60plus, hypertension_str_no_hypertension, stroke	0.466	0.739	1.076
ever_married_Yes, is_old	0.466	0.678	1.076
age_group_merged_60plus, hypertension_str_no_hypertension	0.466	0.739	1.076
married_old	0.466	0.678	1.076
age_group_merged_60plus, hypertension_str_no_hypertension	0.466	0.739	1.076
heart_disease_str_no_heart_disease	0.490	0.865	1.067
heart_disease_str_no_heart_disease, stroke	0.490	0.865	1.067
heart_disease_str_no_heart_disease	0.490	0.865	1.067
gender_Female	0.490	0.604	1.067
gender_Female	0.490	0.604	1.067
gender_Female, stroke	0.490	0.604	1.067
ever_married_Yes, heart_disease_str_no_heart_disease	0.486	0.771	1.066
married_old, stroke	0.486	0.672	1.066
married_old			
ever_married_Yes, heart_disease_str_no_heart_disease			
ever_married_Yes, heart_disease_str_no_heart_disease			
ever_married_Yes, heart_disease_str_no_heart_disease			
age_group_merged_60plus, hypertension_str_no_hypertension, stroke			
work_type_Private			
stroke, work_type_Private			
work_type_Private			
age_group_merged_60plus, hypertension_str_no_hypertension			
age_group_merged_60plus, hypertension_str_no_hypertension			
heart_disease_str_no_heart_disease, is_old			
age_group_merged_60plus, ever_married_Yes			
bmi_group_merged_High, is_old			
stroke, work_type_Private			
hypertension_str_no_hypertension			
hypertension_str_no_hypertension, stroke			
hypertension_str_no_hypertension			
work_type_Private			
work_type_Private			
ever_married_Yes, heart_disease_str_no_heart_disease, stroke	0.486	0.771	1.066
is_old, married_old	0.486	0.672	1.066
age_group_merged_60plus, married_old	0.486	0.672	1.066
married_old	0.486	0.672	1.066
work_type_Private	0.438	0.637	1.065
age_group_merged_60plus, hypertension_str_no_hypertension, stroke	0.438	0.732	1.065
age_group_merged_60plus, hypertension_str_no_hypertension	0.438	0.732	1.065
age_group_merged_60plus, hypertension_str_no_hypertension	0.438	0.732	1.065
work_type_Private	0.438	0.637	1.065
stroke, work_type_Private	0.438	0.637	1.065
age_group_merged_60plus, ever_married_Yes	0.486	0.896	1.063
bmi_group_merged_High, is_old	0.514	0.610	1.061
age_group_merged_60plus, ever_married_Yes	0.514	0.895	1.061
hypertension_str_no_hypertension	0.466	0.779	1.059
stroke, work_type_Private	0.466	0.634	1.059
work_type_Private	0.466	0.634	1.059
work_type_Private	0.466	0.634	1.059
hypertension_str_no_hypertension	0.466	0.779	1.059
hypertension_str_no_hypertension, stroke	0.466	0.779	1.059
hypertension_str_no_hypertension, is_old			
bmi_group_merged_High, married_old			
heart_disease_str_no_heart_disease, is_old			
heart_disease_str_no_heart_disease, is_old, stroke			
hypertension_str_no_hypertension, married_old			
is_old, married_old			
heart_disease_str_no_heart_disease, married_old, stroke			
is_old, married_old, stroke			
heart_disease_str_no_heart_disease, married_old			
age_group_merged_60plus, stroke	0.502	1.000	1.055
age_group_merged_60plus	0.514	1.000	1.055
age_group_merged_60plus, stroke	0.542	1.000	1.055
age_group_merged_60plus	0.542	1.000	1.055
age_group_merged_60plus, stroke	0.466	1.000	1.055
age_group_merged_60plus, stroke	0.631	1.000	1.055
age_group_merged_60plus	0.486	1.000	1.055
age_group_merged_60plus	0.631	1.000	1.055
age_group_merged_60plus, stroke	0.486	1.000	1.055